

目錄

1. 摘要
2. 馬可夫決策框架
3. 賣股問題模型設計
4. 強化學習策略設計
5. 實戰
6. 結論與未來展望
7. 參考文獻

一. 摘要

股票市場有一句名言「會買的是徒弟，會賣的才是師父」，賣股的時機一直是讓投資人頭痛的問題。為了解決這個難題，本研究以量化的角度將其包裝成馬可夫決策過程 (Markov Decision Process, MDP)。透過各種的強化學習方法(Reinforcement Learning policy)：SARSA、Q-learning、SARSA(λ)，設計出賣股策略，目標是提升投資績效。

最佳賣點問題：

1. 問題建模 (Problem Formulation)：

將股票交易中的賣出時機選擇問題，正式定義為一個馬可夫決策過程 (MDP)，使決策過程具備數學上的嚴謹性。

2. 演算法應用 (Methodology)：

採用強化學習 (Reinforcement Learning) 中的 SARSA、Q-learning 以及 SARSA(λ) 演算法，訓練代理人 (Agent) 學習在動態市場環境下的最佳決策。

3. 最佳賣點任務 (Task Definition)：

- 限制條件：投資人必須在未來 T 天的時間窗口內，賣出手中的一支股票。(最晚會在第 T 天強制賣出)
- 報酬計算：考量「機會成本」與「時間價值」，將賣股所得與後續存入銀行的利息總和納入考量。

4. 研究目標 (Objective)：

比較不同策略的表現，旨在設計出一套能顯著提升投資績效的最佳賣股策略。

二. 馬可夫決策框架

參考Powell(2022)，馬可夫決策過程(MDP)有五個核心的要素(Powell Framework)，分別是狀態變數、決策變數、外生資訊、狀態轉移函數以及目標函數，以下分別介紹基本概念。

1. 狀態變數 (State Variables, S_t)

狀態變數代表了在時間點 t 做決策時所擁有的「所有知識與資訊」的集合。根據 Powell 的定義，狀態變數必須具備馬可夫性質 (Markov Property)，即包含所有計算決策及推導下一個狀態所需的必要資訊。 S_t 通常包含以下三類資訊：物理狀態 (Physical State)：例如庫存量、位置、資金餘額等具體資源。資訊狀態 (Information State)：例如當前的市場價格、天氣數據等外在環境數據。信念狀態 (Belief State)：當系統包含不確定參數時 (例如未知的需求分佈參數)，我們對這些參數的主觀機率分佈或估計值。

2. 決策變數 (Decision Variables, x_t)

決策變數是在時間點 t ，根據當前狀態 S_t 所採取的行動或控制量。在強化學習中常被稱為 Action (a_t)。決策必須受到限制條件 (Constraints) 的約束，我們通常用 $\mathcal{X}_t$ 來表示在時間 t 的可行決策集合，因此：

$$x_t \in \mathcal{X}_t$$

決策的產生通常依賴於一個策略 (Policy)，記為 π ，即 $x_t = X^\pi(S_t)$ 。我們的目標就是找到一個表現最好的函數 π 。

3. 外生資訊 (Exogenous Information, W_{t+1})

這是在我們做出決策 x_t 之後，但在時間 $t + 1$ 之前首次得知的新資訊。這是系統隨機性 (Stochasticity) 的來源。這些資訊可能包括：隨機的需求變化。資產價格的波動。系統的隨機故障或延遲。在數學上，我們通常假設 W_{t+1} 是一個隨機變數，其分佈可能依賴於當前的狀態 S_t 。

4. 狀態轉移函數 (Transition Function, S^M)

狀態轉移函數描述了系統如何從時間 t 演變到時間 $t + 1$ 。它是連結狀態、決策與外生資訊的數學模型。不同於傳統 MDP 教科書有時使用轉移矩陣 (Transition Matrix)，Powell 架構強調使用顯式的方程形式：

$$S_{t+1} = S^M(S_t, x_t, W_{t+1})$$

這個函數 $S^M(\cdot)$ 包含了所有的物理守恆定律、邏輯規則或市場演變公式。例如：庫存更新公式 $R_{t+1} = R_t - x_t + \hat{D}_{t+1}$ (其中 $\hat{D}$ 為隨機需求)。

5. 目標函數 (Objective Function)

目標函數用來評估我們決策的好壞。通常由兩部分組成：貢獻/成本函數 (Contribution/Cost Function, $C(S_t, x_t)$)：單期決策帶來的立即收益或成本。期望值 (Expectation)：因為未來充滿不確定性 (由 W 造成)，我們追求的是最大化累積獎勵的期望值。數學上，我們的目標是尋找最佳策略 π^* 來最大化總價值：

$$\max_{\pi} \mathbb{E} \left[\sum_{t=0}^T \gamma^t C(S_t, X^\pi(S_t)) \right]$$

其中 γ 為折現因子 (Discount Factor)。

三. 賣股問題模型設計

本研究在交易策略設計上參考強化學習於金融交易之應用文獻，特別是比較 Q-learning 與 SARSA 的表現 (Corazza & Sangalli, 2015)，並結合隨機最佳化與序列決策之理論架構 (Powell, 2022)，將「股票最佳

賣出時點選擇」問題建構為一個有限期時序決策問題(Finite-horizon sequential decision-making problem)，以下為設計的Powell Framework

1. 狀態變數 (State Variables, S_t)

$$S_t = (e_{t-\ell}, e_{t-(\ell-1)}, \dots, e_{t-1}, e_t, M_t)$$

- t : 目前的時間期數, $t = 0 \sim T$
- e_t : t 時間點的對數報酬(log return), $e_t = \log \frac{P_t}{P_{t-1}}$
- M_t : t 時間點時相對於期初的對數報酬, $M_t = \log \frac{P_t}{P_0}$
- 賣出的話, $S_t = \emptyset$ (terminal state)

如果是均值回歸的信者, 當發現過去一段時間股價報酬一直創新高會考慮賣股; 趨勢交易者發現股價向下突破某一閾值也會考慮賣股。狀態變數的設計考慮了這兩種情況, 因此將一段時間之前的對數報酬(近期報酬)以及目前的總報酬率(長期報酬)考慮進來, 期望擁有更全面的判斷能力。

離散化方法：分位數分箱 (Quantile Binning)

由於 e_t 和 M_t 報酬率都是連續變數, 對於建立Q-table非常不利, 因此我們需要離散化狀態變數。

- 邏輯：將歷史(模擬)資料(單期報酬、累積報酬)切成 n 等份, 再把當前的報酬分配到對應的區間內。
- 特色：不管資料分佈多麼不均勻 (例如極端值很多), 每個箱子裡的資料筆數是一樣多的, 能夠適應不同股價的性質。
- 例子：假設 $n_1 = 4$ (把單期報酬切成 4 等份), 它會找出 25%、50%、75% 的位置當作切點 (Cut-offs), $n_2 = 5$ (把累積報酬切成5等分), 考慮2天的近期報酬。則狀態數目就只剩下 $5 * 4^2$

2. 決策變數 (Decision Variables, x_t)

在尚未賣出且未達到投資期限的情況下, 投資者可以選擇明天($t + 1$)要賣出(Sell)或是繼續 持有(Hold), 但在最後一天 T 時, 必須強制賣出。在任何時間點賣出, 系統都會進入終止狀態(terminal state)

$$x_t = X_t(S_t) = \begin{cases} \{\text{Hold, Sell}\}, & x_{t-1} = \text{Hold} \\ \text{Sell}, & t = T - 1 \end{cases}$$

3. 外生資訊 (Exogenous Information, W_{t+1})

外生資訊定義為驅動股價變動的隨機變數, 可以來自於布朗運動(BM)、碎形布朗運動(fBM)、Heston Model等。

定義 $t + 1$ 時刻的外生資訊向量為：

$$W_{t+1} = Z_{t+1}$$

假如選用BM於模擬環境中, Z_{t+1} 就是標準常態分配變數, 即 $Z_{t+1} \sim N(0, 1)$

4. 狀態轉移函數 (Transition Function, S^M)

我們的狀態是由股價來計算組成, 因此股價狀態的更新能夠代表狀態轉移函數。針對不同的價格隨機模型, 股價的轉移方程也有所不同：

$$P_{t+1} = f(P_t)$$

- $f()$ ：股價隨機過程，例如BM：

$$P_{t+1} = P_t \cdot \exp\left(\left(\mu - \frac{\sigma^2}{2}\right) \Delta t + \sigma \sqrt{\Delta t} Z_{t+1}\right)$$

其中， μ ：預期報酬率 (Drift) σ ：波動率 (Volatility) Δt ：時間間隔 Z_{t+1} ：來自外生資訊 W_{t+1} 的隨機項

配合前述的狀態變數 S_t ，其餘變數（如單期報酬 e_t 、累積報酬 M_t ）亦隨之更新：

$$S_{t+1} = \begin{cases} M_{t+1} = \log \frac{P_{t+1}}{P_0}, e_{t+1} = \log \frac{P_{t+1}}{P_t} & x_t = \text{Hold} \\ \emptyset, & x_t = \text{Sell} \end{cases}$$

5. 目標函數 (Objective Function)

本研究的目標是在有限期限 T 天內，選擇最佳賣出時點，讓期望累積報酬率最大化。

- 選擇持有，則當期不產生即時報酬
- 如果在第 τ 天賣出，所得到的現金 P_τ 會投入銀行並以無風險利率 r_f 滾存到第 T 天

Contibution Function(累積報酬率)

$$C(S_t, x_t) = \begin{cases} 0, & x_t = \text{Hold} \\ \frac{P_{t+1}(1+r_f)^{T-t-1}}{P_0} - 1, & x_t = \text{Sell} \end{cases}$$

最佳策略 π^*

$$\max_{\pi} \mathbb{E} \left[\sum_{t=0}^T C(S_t, X^{\pi}(S_t)) \right]$$

由於任務定義已經考慮了無風險利率報酬的時間成本，所以目標函數不再設計折現率 γ 。

四. 強化學習策略設計

1. SARSA

SARSA 為一種在策略 (On-policy) 的時間差分 (Temporal-Difference, TD) 學習演算法。其核心特點在於：代理人 (agent) 在更新狀態-動作價值時，必須依據實際所採取的動作進行更新，而非假設未來一定會選擇最佳動作。SARSA 在學習過程中，行為策略 (behavior policy) 與被評估的策略 (target policy) 是相同的。代理人根據當前策略 (通常為 ϵ -greedy) 選擇動作，並且在更新 Q 值時，使用「下一狀態中實際選擇的動作」所對應的 Q 值進行更新。因此，SARSA 能夠忠實反映探索行為對學習過程的影響。

SARSA更新公式 (使用實際採取的 x_{t+1})：

$$Q(s_t, x_t) = Q(s_t, x_t) + \alpha[r_{t+1} + \gamma Q(s_{t+1}, x_{t+1}) - Q(s_t, x_t)]$$

註：這裡的 x_{t+1} 是代理人實際會去執行的動作。

最佳賣點任務的SARSA更新規則可以分成兩種情況：

情況 A：當 $x_t = \text{Hold}$

$$Q(s_t, \text{Hold}) \leftarrow Q(s_t, \text{Hold}) + \alpha[0 + 1 \cdot Q(s_{t+1}, x_{t+1}) - Q(s_t, \text{Hold})]$$

(這裡 $\gamma = 1$ 配合 contribution function C 的設計，獎勵是 0)

情況 B：當 $x_t = \text{Sell}$

$$Q(s_t, \text{Sell}) \leftarrow Q(s_t, \text{Sell}) + \alpha[C(S_t, \text{Sell}) + 0 - Q(s_t, \text{Sell})]$$

(因為賣出後遊戲結束，沒有下一期的 Q 值)

其中：

- $\alpha \in (0, 1]$ ：學習率 (learning rate)，控制每次更新對舊 Q 值的影響程度
- $Q(s, x)$ ：狀態-動作對應的 Q 值

2. Q-learning

Q-Learning 為一種離策略 (Off-policy) 學習演算法。其特點在於：代理人 (agent) 在更新狀態-動作價值時，不依賴實際執行的動作，而是根據「在下一個狀態中能使 Q 值最大的動作」來進行更新。

換言之，Q-Learning 在學習過程中，行為策略 (behavior policy) 與被評估的策略 (target policy) 是不同的。即使代理人因探索而執行了非最佳動作，更新時仍假設未來會選擇最佳行動。

Q-learning 更新公式 (使用理論最佳的 $\max x'$)：

$$Q(s_t, x_t) = Q(s_t, x_t) + \alpha[r_{t+1} + \gamma \max_{x'} Q(s_{t+1}, x') - Q(s_t, x_t)]$$

註：這裡不管代理人實際上會做什麼，直接取最大值來更新。

最佳賣點任務的 Q-learning 更新規則也可以分成兩種情況：

情況 A：當 $x_t = \text{Hold}$

$$Q(s_t, \text{Hold}) \leftarrow Q(s_t, \text{Hold}) + \alpha[0 + 1 \cdot \max_{x'} Q(s_{t+1}, x') - Q(s_t, \text{Hold})]$$

情況 B：當 $x_t = \text{Sell}$

$$Q(s_t, \text{Sell}) \leftarrow Q(s_t, \text{Sell}) + \alpha[C(S_t, \text{Sell}) + 0 - Q(s_t, \text{Sell})]$$

3. SARSA(λ)

SARSA(λ) 是 SARSA 的改進版本，它引入了資格跡 (Eligibility Traces, E_t) 的概念。傳統的 SARSA (即 $\lambda = 0$) 每次只更新前一步的 Q 值，屬於「短視」的更新；而 SARSA(λ) 則允許獎勵向後傳遞給過去一連串導致當前狀態的動作。

在我們的賣股任務中，這一點特別重要。假設代理人連續「持有」了 20 天，並在第 21 天「賣出」獲得高額報酬。傳統 SARSA 需要重複經歷非常多次這個過程，才能慢慢將第 21 天的獎勵一步步傳回第 1 天；而 SARSA(λ) 能透過資格跡，在一次賣出後，立即更新過去這 20 天所有「持有」決策的價值，大幅提升學習效率。

核心機制：資格跡 (Eligibility Traces)

我們為每一個狀態-動作對 (s, x) 維護一個變數 $E(s, x)$ 。

- 當代理人訪問 (s_t, x_t) 時， $E(s_t, x_t)$ 會增加 (通常加 1)。
- 隨著時間推移，所有 $E(s, x)$ 會以 $\gamma\lambda$ 的速率衰減。
- 更新時，不只更新當前的 Q 值，而是按 $E(s, x)$ 的比例更新所有走過的狀態。

SARSA(λ) 更新公式：

首先計算 TD 誤差 (TD Error, δ_t)：

$$\delta_t = r_{t+1} + \gamma Q(s_{t+1}, x_{t+1}) - Q(s_t, x_t)$$

接著更新所有狀態的 Q 值與資格跡：

$$E_t(s, x) \leftarrow \gamma \lambda E_{t-1}(s, x) + 1(s = s_t, x = x_t)$$

$$Q(s, x) \leftarrow Q(s, x) + \alpha \delta_t E_t(s, x)$$

最佳賣點任務的 SARSA(λ) 更新規則同樣依據是否賣出分為兩種情況：

情況 A：當 $x_t = \text{Hold}$

1. 計算誤差： $\delta_t = 0 + 1 \cdot Q(s_{t+1}, x_{t+1}) - Q(s_t, \text{Hold})$
2. 增加當前狀態的資格跡： $E(s_t, \text{Hold}) \leftarrow E(s_t, \text{Hold}) + 1$
3. 更新所有 (s, x) 的 Q 值： $Q(s, x) \leftarrow Q(s, x) + \alpha \delta_t E(s, x)$
4. 衰減所有資格跡： $E(s, x) \leftarrow 1 \cdot \lambda \cdot E(s, x)$

情況 B：當 $x_t = \text{Sell}$

1. 計算誤差： $\delta_t = C(s_t, \text{Sell}) + 0 - Q(s_t, \text{Sell})$ (賣出即終止，未來價值為0)
2. 增加當前狀態的資格跡： $E(s_t, \text{Sell}) \leftarrow E(s_t, \text{Sell}) + 1$
3. 更新所有 (s, x) 的 Q 值： $Q(s, x) \leftarrow Q(s, x) + \alpha \delta_t E(s, x)$
4. 因為 Episode 結束，重置所有 $E(s, x) = 0$ ，準備下一回合。

其中：

- $\lambda \in [0, 1]$ ：衰減因子。 $\lambda = 0$ 即為傳統 SARSA； $\lambda = 1$ 類似於蒙地卡羅方法 (Monte Carlo)，等到結局才算總帳。
- $E(s, x)$ ：紀錄某個狀態動作對在近期被訪問的頻率與時間遠近。

五. 實戰

回測環境設定

a. 選取資產：上市台股1000檔

b. 最大回測時間：2000-01-04 ~ 2025-11-19

c. 賣出規則：在測試期間的T天內，可以根據至第t天之前的資訊判斷，並且以隔日第t+1天的價格賣出。

d. RL方法：QL、SARSA、SARSA(λ)，隨機來源使用BM、fBM(-f)。

e. 比較對象：基礎策略，B&H、、；以及技術指標，MA、KD、RSI、MACD、。

f. 回測方法：採用時間序列之拔靴法(bootstrap methods for time series) (Haruiv,2017; Efron & Tibshirani,1993)

補充：

B&H：買入持有，最後一天賣出

🔍：隨機挑一天賣出

💰：第一天賣出股票存銀行，賺取利息。

MA：若短天期均線($n=5$) < 長天期均線($n=20$)，賣出

KD：若K線 < D線($n=9$)，賣出

RSI：rsi值($n=14$) > 70 表示股票過熱，賣出

MACD：macd柱狀圖(12,26,9) < 0，賣出

時間序列之拔靴法：隨機挑選一支股票的一段連續時間(例如500天)當作訓練資料，並且在接下來的100天(也就是第501~600天)作為測試資料，用以比較各種方法的績效。此方法可在保留時間相依結構的情況下進行重抽樣，能夠降低單一樣本區間可能導致的樣本偏誤，提升績效結果的可靠性。

-0.0027142710678186065 0.03190366782002177

實驗1. 100天賣股

- e_t : 參考近3期的股票報酬，使用標準差法離散化為5個區塊
- M_t : 使用百分位數法離散為9個區塊
- α : 0.1
- γ : 0.85
- ϵ : 0.2
- λ : 0.4
- RL訓練次數為狀態數量的10倍
- 測試100天
- 訓練長度為測試的7倍
- 總共960次的測試

100%|██████████| 960/960 [22:12<00:00, 1.39s/it]

QLf: (-1.81,-1.57)|(3, 5, 9) = 1125, ((0.1, 0.85, 0.2, 0.4)), len=7

實際報酬比較

	QL	SARSA	SARSA(λ)	B&H	?	MA	KD	R
SI	MACD		QLf	SARSAf	SARSA(λ)f			
count	96000.00%	96000.00%	96000.00%	96000.00%	96000.00%	96000.00%	96000.00%	96000.00%
mean	3.17%	1.52%	2.81%	7.39%	4.52%	1.39%	0.91%	2.92%
1.48%	0.79%	1.85%	1.39%	2.83%				
std	41.87%	7.80%	39.66%	50.98%	43.98%	6.77%	6.88%	21.89%
7.34%	2.95%	7.73%	7.93%	42.23%				
min	-50.07%	-41.04%	-40.94%	-56.60%	-56.11%	-28.33%	-49.97%	-56.60%
-30.95%	-49.55%	-50.07%	-51.29%	-44.43%				
25%	0.23%	0.06%	0.26%	-9.76%	-6.25%	-1.03%	-2.11%	-6.47%
-1.16%	-0.23%	0.21%	-0.02%	0.10%				
50%	1.91%	1.96%	2.40%	0.75%	0.71%	0.79%	0.70%	0.56%
0.79%	0.79%	2.07%	1.91%	2.27%				
75%	4.40%	4.43%	5.13%	13.39%	8.87%	2.84%	3.12%	7.67%
2.91%	1.70%	4.60%	4.33%	5.02%				
max	1277.35%	35.67%	1199.03%	1277.46%	1183.17%	74.94%	60.35%	247.87%
79.83%	10.85%	32.79%	34.28%	1277.35%				

報酬排名比較

	QL	SARSA	SARSA(λ)	B&H	?	MA	KD	RSI	MACD	
QLf	SARSAf	SARSA(λ)f								
count	960.00	960.00	960.00	960.00	960.00	960.00	960.00	960.00	960.00	960.00
0	960.00	960.00								
mean	5.20	5.28	5.25	6.79	7.14	7.44	7.96	7.25	7.41	7.89
8	5.24	5.37								
std	2.95	3.14	3.32	4.98	4.55	3.59	3.49	4.52	3.57	3.91
4	3.07	3.39								
min	1.00	1.00	1.00	1.00	1.00	1.00	1.00	1.00	1.00	1.00
0	1.00	1.00								
25%	3.00	3.00	3.00	1.00	3.00	4.00	5.00	2.00	4.00	5.00
0	3.00	3.00								
50%	5.00	5.00	5.00	7.00	8.00	8.00	9.00	8.00	8.00	9.00
0	5.00	5.00								
75%	7.00	7.00	8.00	12.00	12.00	10.00	11.00	12.00	10.00	11.00
0	7.00	8.00								
max	13.00	13.00	13.00	13.00	13.00	13.00	13.00	13.00	13.00	13.00
0	13.00	13.00								

結果分析-實驗1(100天)

以下歸納RL方法在本實驗中的核心優勢。

1. 壓倒性的中位數表現（勝率的保證）

中位數（Median）代表了策略在「大多數情況下」的表現。這是 RL 方法最強大的護城河。

- RL 完勝 B&H：
 - B&H 中位數僅 0.75%，這意味著有一半的時間，買入持有策略的獲利微乎其微，甚至不如銀行利息（0.79%）。
 - RL 方法（如 QLf, SARSA(λ)) 中位數高達 2.07%~2.40%。
 - 結論：在隨機的市場波動中，RL 策略能穩定地創造出比 B&H 高出近 3 倍的中位數回報。這證明了 RL 能夠有效過濾無效波動，在有獲利時果斷落袋。

2. 排名穩定性居冠

從報酬排名（Rank）來看，RL 是表現最穩定的策略群體。

- 平均排名第一：
 - QLf (使用 fBM 訓練) 取得了全場最佳的平均排名 4.98，是唯一平均排名進入前 5 名的策略。
 - 相比之下，B&H 平均排名為 6.79，MA 為 7.44，KD 為 7.96。
- 穩定的前段班：
 - RL 方法的排名標準差 (Std) 顯著低於 B&H，且中位數排名穩定維持在 5。這代表 RL 策略極少墊底，無論市場好壞，它都能維持在所有策略的前半段。

實驗2. 30天賣出

- e_t : 參考近3期的股票報酬，使用標準差法離散化為5個區塊
- M_t : 使用百分位數法離散為9個區塊
- $\alpha : 0.1$
- $\gamma : 0.85$
- $\epsilon : 0.2$
- $\lambda : 0.4$
- RL訓練次數為狀態數量的10倍
- 測試30天
- 訓練長度為測試的7倍
- 總共960次的測試

100%|██████████| 960/960 [14:49<00:00, 1.08it/s]

SARSA(λ): (-0.86, -0.81) | (3, 5, 9) = 1125, ((0.1, 0.85, 0.2, 0.4)), len=7
實際報酬比較

	QL	SARSA	SARSA(λ)	B&H	?	MA	KD	R
SI	MACD		QLf	SARSAf	SARSA(λ)f			
count	96000.00%	96000.00%	96000.00%	96000.00%	96000.00%	96000.00%	96000.00%	96000.00%
mean	0.47%	0.64%	0.68%	1.89%	1.36%	0.76%	0.48%	1.54%
0.78%	0.25%	0.33%	0.31%	0.71%				
std	7.89%	8.00%	8.88%	16.31%	11.92%	7.19%	5.34%	15.16%
6.35%	2.30%	8.18%	8.54%	8.66%				
min	-40.82%	-40.26%	-40.26%	-40.81%	-40.81%	-50.69%	-49.29%	-40.81%
-50.69%	-9.79%	-40.82%	-40.82%	-40.26%				
25%	-0.83%	-0.68%	-1.28%	-6.08%	-3.40%	-1.63%	-1.38%	-5.38%
-1.32%	-0.69%	-1.15%	-1.12%	-1.22%				
50%	1.03%	1.00%	1.51%	0.01%	0.10%	0.22%	0.21%	0.01%
0.23%	0.24%	1.04%	1.03%	1.52%				
75%	3.64%	3.69%	4.58%	6.73%	3.95%	1.97%	2.00%	5.39%
2.03%	1.05%	3.55%	3.55%	4.51%				
max	39.91%	39.91%	39.91%	97.92%	85.42%	82.84%	49.74%	96.62%
43.73%	11.59%	39.91%	85.53%	60.32%				

報酬排名比較

	QL	SARSA	SARSA(λ)	B&H	?	MA	KD	RSI	MACD	
QLf	SARSAf	SARSA(λ)f								
count	960.00	960.00	960.00	960.00	960.00	960.00	960.00	960.00	960.00	960.00
0	960.00	960.00								
mean	5.48	5.50	5.45	6.32	7.30	7.05	7.19	6.57	6.89	7.48
3	5.50	5.46								
std	3.10	3.09	3.29	4.34	4.12	3.81	3.72	4.24	3.69	4.23
5	3.16	3.33								
min	1.00	1.00	1.00	1.00	1.00	1.00	1.00	1.00	1.00	1.00
0	1.00	1.00								
25%	3.00	3.00	3.00	1.00	3.00	3.00	4.00	2.00	3.00	4.00
0	3.00	3.00								
50%	5.00	5.00	5.00	6.50	8.00	7.00	8.00	7.00	7.00	9.00
0	5.00	5.00								
75%	8.00	8.00	8.00	11.00	11.00	11.00	10.00	11.00	10.00	11.00
0	8.00	8.00								
max	13.00	13.00	13.00	13.00	13.00	13.00	13.00	13.00	13.00	13.00
0	13.00	13.00								

結果分析-實驗2(30天)

即使賣出天數調降至30天(短天期)，RL賣出方法的中位數優勢依舊存在，排名的平均還比B&H少了0.81，也就是說RL是穩穩賺錢的好方法。

實驗3. 100天賣出，強化版TA

參數設定和實驗1相同，但是強化了技術分析(TA)的賣出邏輯，賣出方法調整如下：

- MA：慢線 < 快線 $\Rightarrow$ 慢線由上往下穿越快線死亡交叉
- RSI：rsi > 70 $\Rightarrow$ 昨天 > 70 且 今天 < 70
- KD：K值 < D值 $\Rightarrow$ 高檔鈍化(K值>80)後死叉
- MACD：macd柱狀體 < 0 $\Rightarrow$ 昨天hist > 0 且 今天 hist < 0

100% | 960/960 [22:04<00:00, 1.38s/it]

SARSA(λ): (-1.27, -1.18) | (3, 5, 9) = 1125, ((0.1, 0.85, 0.2, 0.4)), len=7

實際報酬比較

	QL	SARSA	SARSA(λ)	B&H	?	MA	KD	R
SI	MACD		QLf	SARSAf	SARSA(λ)f			
count	96000.00%	96000.00%	96000.00%	96000.00%	96000.00%	96000.00%	96000.00%	96000.00%
96000.00%	96000.00%	96000.00%	96000.00%	96000.00%	96000.00%			
mean	1.78%	2.05%	2.26%	5.40%	3.37%	2.61%	3.45%	3.45%
2.05%	0.85%	1.96%	1.89%	2.15%				
std	8.66%	8.72%	9.82%	28.66%	19.08%	15.72%	23.17%	22.33%
14.90%	2.37%	9.25%	8.22%	9.62%				
min	-50.38%	-42.94%	-48.12%	-53.95%	-47.12%	-38.81%	-52.45%	-53.95%
-44.80%	-9.29%	-50.38%	-41.24%	-47.85%				
25%	0.07%	0.07%	0.70%	-10.80%	-6.01%	-4.22%	-6.72%	-7.05%
-4.31%	-0.20%	0.12%	0.08%	0.28%				
50%	1.95%	2.00%	2.58%	0.46%	0.79%	0.64%	0.96%	0.69%
0.68%	0.79%	1.96%	1.89%	2.40%				
75%	4.32%	4.69%	5.29%	14.35%	8.77%	6.28%	8.89%	8.33%
5.34%	1.73%	4.20%	4.20%	5.32%				
max	76.78%	95.19%	105.53%	243.40%	147.11%	204.34%	243.40%	207.97%
208.39%	12.03%	102.01%	95.66%	95.19%				

報酬排名比較

	QL	SARSA	SARSA(λ)	B&H	?	MA	KD	RSI	MACD	
QLf	SARSAf	SARSA(λ)f								
count	960.00	960.00	960.00	960.00	960.00	960.00	960.00	960.00	960.00	960.00
0	960.00	960.00								
mean	5.56	5.44	5.40	6.67	7.10	7.24	6.86	7.00	7.45	8.04
9	5.54	5.55								
std	3.09	3.03	3.16	4.71	4.15	3.90	4.21	4.17	3.77	4.03
7	3.08	3.25								
min	1.00	1.00	1.00	1.00	1.00	1.00	1.00	1.00	1.00	1.00
0	1.00	1.00								
25%	3.00	3.00	3.00	1.00	3.00	4.00	3.00	3.00	4.00	5.00
0	3.00	3.00								
50%	5.00	5.00	5.00	7.00	7.50	8.00	8.00	8.00	8.00	9.00
0	5.00	5.00								
75%	8.00	8.00	7.00	11.00	11.00	11.00	11.00	11.00	11.00	12.00
0	8.00	8.00								
max	13.00	13.00	13.00	13.00	13.00	13.00	13.00	13.00	13.00	13.00
0	13.00	13.00								

另一組參數設計

- e_t : 參考近7期的股票報酬，使用標準差法離散化為2個區塊
- M_t : 使用百分位數法離散為2個區塊
- α : 0.1
- γ : 0.85
- ϵ : 0.25
- λ : 0.25
- RL訓練次數為狀態數量的10倍
- 測試100天
- 訓練長度為測試的6倍
- 總共960次的測試

100% | | 960/960 [05:09<00:00, 3.10it/s]

SARSA: $(-1.53, -1.33) | (7, 2, 2) = 256, ((0.1, 0.85, 0.25, 0.25)), \text{len}=6$
 實際報酬比較

	QL	SARSA	SARSA(λ)	B&H	?	MA	KD	R
SI	MACD		QLf	SARSAf	SARSA(λ)f			
count	96000.00%	96000.00%	96000.00%	96000.00%	96000.00%	96000.00%	96000.00%	96000.00%
mean	2.21%	2.43%	2.41%	7.17%	3.85%	2.97%	4.03%	4.73%
2.40%	0.82%	2.13%	2.31%	2.12%				
std	10.38%	10.19%	10.34%	37.40%	21.39%	15.70%	25.10%	26.90%
13.62%	2.48%	10.35%	10.11%	10.51%				
min	-57.84%	-57.84%	-57.84%	-73.40%	-69.43%	-49.02%	-71.78%	-71.47%
-49.02%	-9.24%	-57.84%	-57.60%	-56.68%				
25%	-0.18%	-0.11%	-0.03%	-8.95%	-5.78%	-3.35%	-6.47%	-6.32%
-3.09%	-0.15%	-0.22%	-0.02%	-0.20%				
50%	2.61%	2.68%	2.76%	0.72%	0.90%	1.14%	0.68%	0.98%
1.07%	0.79%	2.60%	2.57%	2.75%				
75%	5.85%	5.98%	6.29%	14.74%	8.15%	5.93%	9.28%	9.39%
5.13%	1.66%	5.82%	5.92%	5.93%				
max	53.19%	53.19%	53.19%	516.72%	153.76%	229.17%	271.99%	331.93%
140.86%	10.87%	53.19%	62.79%	53.19%				

報酬排名比較

	QL	SARSA	SARSA(λ)	B&H	?	MA	KD	RSI	MACD	
QLf	SARSAf	SARSA(λ)f								
count	960.00	960.00	960.00	960.00	960.00	960.00	960.00	960.00	960.00	960.00
0	960.00	960.00								
mean	5.41	5.19	5.32	6.72	7.30	7.31	6.95	6.95	7.56	8.08
3	5.43	5.56								
std	3.10	3.08	3.17	4.72	4.12	3.74	4.18	4.21	3.68	4.21
5	3.23	3.23								
min	1.00	1.00	1.00	1.00	1.00	1.00	1.00	1.00	1.00	1.00
0	1.00	1.00								
25%	3.00	3.00	3.00	1.00	3.00	4.00	3.00	3.00	4.00	5.00
0	3.00	3.00								
50%	5.00	5.00	5.00	8.00	8.00	8.00	8.00	8.00	8.00	9.00
0	5.00	5.00								
75%	7.00	7.00	7.00	11.00	11.00	10.00	11.00	11.00	11.00	12.00
0	7.00	8.00								
max	13.00	13.00	13.00	13.00	13.00	13.00	13.00	13.00	13.00	13.00
0	13.00	13.00								

結果分析-實驗3(100天，強化TA)

強化TA比原本的簡單TA好很多，平均報酬還有排名都到了能夠與隨機賣出一較高下的地步，但是RL的中位數以及排名仍然大幅輾壓這些基本、技術分析的方法。因此使用技術分析，不如長期持有或是用這裡的RL方法。

六. 結論與未來展望

本文使用三種RL方法，Q-learning、SARSA、SARSA(λ)來自動選擇最佳的賣股時機點，並且使用時間序列的拔靴法進行回測。與基本和技術分析方法比較，在中位數、Q1報酬以及報酬排名上大幅領先，表示RL能夠穩定的賺取報酬，取得了漂亮的成就。

未來可以嘗試reward改成別的績效指標，例如Sharpe或是Utility函數。或是不要一次賣出股票，動作可以換成一次賣出一部份的股票，讓操作更符合實務。

七.參考文獻

Corazza, M., & Sangalli, A. (2015). Q-learning and SARSA: A comparison between two intelligent stochastic control approaches for financial trading (Working Paper No. 15/WP/2015). Department of Economics, Ca' Foscari University of Venice.

Efron, B., & Tibshirani, R. J. (1993). An introduction to the bootstrap. New York, NY: Chapman & Hall/CRC.

Haruvi, Y. (2017). Applying bootstrap methods to time series and regression models. M.Sc. Seminar in Statistics, Tel Aviv University.

Powell, W. B. (2022). Reinforcement learning and stochastic optimization: A unified framework for sequential decisions. Hoboken, NJ: John Wiley & Sons.