

# 目錄

1. 摘要
2. 馬可夫決策框架
3. 賣股問題模型設計
4. 強化學習策略設計
5. 實戰
6. 結論與未來展望
7. 參考文獻

## 一. 摘要

股票市場有一句名言「會買的是徒弟，會賣的才是師父」，賣股的時機一直是讓投資人頭痛的問題。為了解決這個難題，本研究以量化的角度將其包裝成馬可夫決策過程 (Markov Decision Process, MDP)。透過各種的強化學習方法(Reinforcement Learning policy)：SARSA、Q-learning、SARSA( $\lambda$ )，設計出賣股策略，目標是提升投資績效。

### 最佳賣點問題：

#### 1. 問題建模 (Problem Formulation)：

將股票交易中的賣出時機選擇問題，正式定義為一個馬可夫決策過程 (MDP)，使決策過程具備數學上的嚴謹性。

#### 2. 演算法應用 (Methodology)：

採用強化學習 (Reinforcement Learning) 中的 SARSA、Q-learning 以及 SARSA( $\lambda$ ) 演算法，訓練代理人 (Agent) 學習在動態市場環境下的最佳決策。

#### 3. 最佳賣點任務 (Task Definition)：

- 限制條件：投資人必須在未來  $T$  天的時間窗口內，賣出手中的一支股票。(最晚會在第  $T$  天強制賣出)
- 報酬計算：考量「機會成本」與「時間價值」，將賣股所得與後續存入銀行的利息總和納入考量。

#### 4. 研究目標 (Objective)：

比較不同策略的表現，旨在設計出一套能顯著提升投資績效的最佳賣股策略。

## 二. 馬可夫決策框架

參考Powell(2022)，馬可夫決策過程(MDP)有五個核心的要素(Powell Framework)，分別是狀態變數、決策變數、外生資訊、狀態轉移函數以及目標函數，以下分別介紹基本概念。

## 1. 狀態變數 (State Variables, $S_t$ )

狀態變數代表了在時間點  $t$  做決策時所擁有的「所有知識與資訊」的集合。根據 Powell 的定義，狀態變數必須具備馬可夫性質 (Markov Property)，即包含所有計算決策及推導下一個狀態所需的必要資訊。 $S_t$  通常包含以下三類資訊：物理狀態 (Physical State)：例如庫存量、位置、資金餘額等具體資源。資訊狀態 (Information State)：例如當前的市場價格、天氣數據等外在環境數據。信念狀態 (Belief State)：當系統包含不確定參數時 (例如未知的需求分佈參數)，我們對這些參數的主觀機率分佈或估計值。

## 2. 決策變數 (Decision Variables, $x_t$ )

決策變數是在時間點  $t$ ，根據當前狀態  $S_t$  所採取的行動或控制量。在強化學習中常被稱為 Action ( $a_t$ )。決策必須受到限制條件 (Constraints) 的約束，我們通常用  $\mathcal{X}_t$  來表示在時間  $t$  的可行決策集合，因此：

$$x_t \in \mathcal{X}_t$$

決策的產生通常依賴於一個策略 (Policy)，記為  $\pi$ ，即  $x_t = X^\pi(S_t)$ 。我們的目標就是找到一個表現最好的函數  $\pi$ 。

## 3. 外生資訊 (Exogenous Information, $W_{t+1}$ )

這是在我們做出決策  $x_t$  之後，但在時間  $t + 1$  之前首次得知的新資訊。這是系統隨機性 (Stochasticity) 的來源。這些資訊可能包括：隨機的需求變化。資產價格的波動。系統的隨機故障或延遲。在數學上，我們通常假設  $W_{t+1}$  是一個隨機變數，其分佈可能依賴於當前的狀態  $S_t$ 。

## 4. 狀態轉移函數 (Transition Function, $S^M$ )

狀態轉移函數描述了系統如何從時間  $t$  演變到時間  $t + 1$ 。它是連結狀態、決策與外生資訊的數學模型。不同於傳統 MDP 教科書有時使用轉移矩陣 (Transition Matrix)，Powell 架構強調使用顯式的方程形式：

$$S_{t+1} = S^M(S_t, x_t, W_{t+1})$$

這個函數  $S^M(\cdot)$  包含了所有的物理守恆定律、邏輯規則或市場演變公式。例如：庫存更新公式  $R_{t+1} = R_t - x_t + \hat{D}_{t+1}$  (其中  $\hat{D}$  為隨機需求)。

## 5. 目標函數 (Objective Function)

目標函數用來評估我們決策的好壞。通常由兩部分組成：貢獻/成本函數 (Contribution/Cost Function,  $C(S_t, x_t)$ )：單期決策帶來的立即收益或成本。期望值 (Expectation)：因為未來充滿不確定性 (由  $W$  造成)，我們追求的是最大化累積獎勵的期望值。數學上，我們的目標是尋找最佳策略  $\pi^*$  來最大化總價值：

$$\max_{\pi} \mathbb{E} \left[ \sum_{t=0}^T \gamma^t C(S_t, X^\pi(S_t)) \right]$$

其中  $\gamma$  為折現因子 (Discount Factor)。

# 三. 賣股問題模型設計

本研究在交易策略設計上參考強化學習於金融交易之應用文獻，特別是比較 Q-learning 與 SARSA 的表現 (Corazza & Sangalli, 2015)，並結合隨機最佳化與序列決策之理論架構 (Powell, 2022)，將「股票最佳

賣出時點選擇」問題建構為一個有限期時序決策問題(Finite-horizon sequential decision-making problem)，以下為設計的Powell Framework

## 1. 狀態變數 (State Variables, $S_t$ )

$$S_t = (e_{t-\ell}, e_{t-(\ell-1)}, \dots, e_{t-1}, e_t, M_t)$$

- $t$ : 目前的時間期數,  $t = 0 \sim T$
- $e_t$ :  $t$ 時間點的對數報酬(log return),  $e_t = \log \frac{P_t}{P_{t-1}}$
- $M_t$ :  $t$ 時間點時相對於期初的對數報酬,  $M_t = \log \frac{P_t}{P_0}$
- 賣出的話,  $S_t = \emptyset$ (terminal state)

如果是均值回歸的信者, 當發現過去一段時間股價報酬一直創新高會考慮賣股; 趨勢交易者發現股價向下突破某一閾值也會考慮賣股。狀態變數的設計考慮了這兩種情況, 因此將一段時間之前的對數報酬(近期報酬)以及目前的總報酬率(長期報酬)考慮進來, 期望擁有更全面的判斷能力。

## 離散化方法：分位數分箱 (Quantile Binning)

由於 $e_t$ 和 $M_t$ 報酬率都是連續變數, 對於建立Q-table非常不利, 因此我們需要離散化狀態變數。

- 邏輯：將歷史(模擬)資料(單期報酬、累積報酬)切成  $n$  等份, 再把當前的報酬分配到對應的區間內。
- 特色：不管資料分佈多麼不均勻 (例如極端值很多), 每個箱子裡的資料筆數是一樣多的, 能夠適應不同股價的性質。
- 例子：假設  $n_1 = 4$  (把單期報酬切成 4 等份), 它會找出 25%、50%、75% 的位置當作切點 (Cut-offs),  $n_2 = 5$  (把累積報酬切成5等分), 考慮2天的近期報酬。則狀態數目就只剩下  $5 * 4^2$

## 2. 決策變數 (Decision Variables, $x_t$ )

在尚未賣出且未達到投資期限的情況下, 投資者可以選擇明天( $t + 1$ )要賣出(Sell)或是繼續 持有(Hold), 但在最後一天 $T$ 時, 必須強制賣出。在任何時間點賣出, 系統都會進入終止狀態(terminal state)

$$x_t = X_t(S_t) = \begin{cases} \{\text{Hold, Sell}\}, & x_{t-1} = \text{Hold} \\ \text{Sell}, & t = T - 1 \end{cases}$$

## 3. 外生資訊 (Exogenous Information, $W_{t+1}$ )

外生資訊定義為驅動股價變動的隨機變數, 可以來自於布朗運動(BM)、碎形布朗運動(fBM)、Heston Model等。

定義  $t + 1$  時刻的外生資訊向量為：

$$W_{t+1} = Z_{t+1}$$

假如選用BM於模擬環境中,  $Z_{t+1}$ 就是標準常態分配變數, 即 $Z_{t+1} \sim N(0, 1)$

## 4. 狀態轉移函數 (Transition Function, $S^M$ )

我們的狀態是由股價來計算組成, 因此股價狀態的更新能夠代表狀態轉移函數。針對不同的價格隨機模型, 股價的轉移方程也有所不同：

$$P_{t+1} = f(P_t)$$

- $f()$ ：股價隨機過程，例如BM：

$$P_{t+1} = P_t \cdot \exp\left(\left(\mu - \frac{\sigma^2}{2}\right) \Delta t + \sigma \sqrt{\Delta t} Z_{t+1}\right)$$

其中， $\mu$ ：預期報酬率 (Drift)  $\sigma$ ：波動率 (Volatility)  $\Delta t$ ：時間間隔  $Z_{t+1}$ ：來自外生資訊  $W_{t+1}$  的隨機項

配合前述的狀態變數  $S_t$ ，其餘變數（如單期報酬  $e_t$ 、累積報酬  $M_t$ ）亦隨之更新：

$$S_{t+1} = \begin{cases} M_{t+1} = \log \frac{P_{t+1}}{P_0}, e_{t+1} = \log \frac{P_{t+1}}{P_t} & x_t = \text{Hold} \\ \emptyset, & x_t = \text{Sell} \end{cases}$$

## 5. 目標函數 (Objective Function)

本研究的目標是在有限期限  $T$  天內，選擇最佳賣出時點，讓期望累積報酬率最大化。

- 選擇持有，則當期不產生即時報酬
- 如果在第  $\tau$  天賣出，所得到的現金  $P_\tau$  會投入銀行並以無風險利率  $r_f$  滾存到第  $T$  天

### Contibution Function(累積報酬率)

$$C(S_t, x_t) = \begin{cases} 0, & x_t = \text{Hold} \\ \frac{P_{t+1}(1+r_f)^{T-t-1}}{P_0} - 1, & x_t = \text{Sell} \end{cases}$$

### 最佳策略 $\pi^*$

$$\max_{\pi} \mathbb{E} \left[ \sum_{t=0}^T C(S_t, X^{\pi}(S_t)) \right]$$

由於任務定義已經考慮了無風險利率報酬的時間成本，所以目標函數不再設計折現率  $\gamma$ 。

## 四. 強化學習策略設計

### 1. SARSA

SARSA 為一種在策略 (On-policy) 的時間差分 (Temporal-Difference, TD) 學習演算法。其核心特點在於：代理人 (agent) 在更新狀態-動作價值時，必須依據實際所採取的動作進行更新，而非假設未來一定會選擇最佳動作。SARSA 在學習過程中，行為策略 (behavior policy) 與被評估的策略 (target policy) 是相同的。代理人根據當前策略 (通常為  $\epsilon$ -greedy) 選擇動作，並且在更新 Q 值時，使用「下一狀態中實際選擇的動作」所對應的 Q 值進行更新。因此，SARSA 能夠忠實反映探索行為對學習過程的影響。

### SARSA更新公式 (使用實際採取的 $x_{t+1}$ )：

$$Q(s_t, x_t) = Q(s_t, x_t) + \alpha[r_{t+1} + \gamma Q(s_{t+1}, x_{t+1}) - Q(s_t, x_t)]$$

註：這裡的  $x_{t+1}$  是代理人實際會去執行的動作。

### 最佳賣點任務的SARSA更新規則可以分成兩種情況：

情況 A：當  $x_t = \text{Hold}$

$$Q(s_t, \text{Hold}) \leftarrow Q(s_t, \text{Hold}) + \alpha[0 + 1 \cdot Q(s_{t+1}, x_{t+1}) - Q(s_t, \text{Hold})]$$

(這裡  $\gamma = 1$  配合 contribution function  $C$  的設計，獎勵是 0)

情況 B：當  $x_t = \text{Sell}$

$$Q(s_t, \text{Sell}) \leftarrow Q(s_t, \text{Sell}) + \alpha[C(S_t, \text{Sell}) + 0 - Q(s_t, \text{Sell})]$$

(因為賣出後遊戲結束，沒有下一期的 Q 值)

其中：

- $\alpha \in (0, 1]$ ：學習率 (learning rate)，控制每次更新對舊 Q 值的影響程度
- $Q(s, x)$ ：狀態-動作對應的 Q 值

## 2. Q-learning

Q-Learning 為一種離策略 (Off-policy) 學習演算法。其特點在於：代理人 (agent) 在更新狀態-動作價值時，不依賴實際執行的動作，而是根據「在下一個狀態中能使 Q 值最大的動作」來進行更新。

換言之，Q-Learning 在學習過程中，行為策略 (behavior policy) 與被評估的策略 (target policy) 是不同的。即使代理人因探索而執行了非最佳動作，更新時仍假設未來會選擇最佳行動。

**Q-learning 更新公式 (使用理論最佳的  $\max x'$ )：**

$$Q(s_t, x_t) = Q(s_t, x_t) + \alpha[r_{t+1} + \gamma \max_{x'} Q(s_{t+1}, x') - Q(s_t, x_t)]$$

註：這裡不管代理人實際上會做什麼，直接取最大值來更新。

**最佳賣點任務的 Q-learning 更新規則也可以分成兩種情況：**

情況 A：當  $x_t = \text{Hold}$

$$Q(s_t, \text{Hold}) \leftarrow Q(s_t, \text{Hold}) + \alpha[0 + 1 \cdot \max_{x'} Q(s_{t+1}, x') - Q(s_t, \text{Hold})]$$

情況 B：當  $x_t = \text{Sell}$

$$Q(s_t, \text{Sell}) \leftarrow Q(s_t, \text{Sell}) + \alpha[C(S_t, \text{Sell}) + 0 - Q(s_t, \text{Sell})]$$

## 3. SARSA( $\lambda$ )

SARSA( $\lambda$ ) 是 SARSA 的改進版本，它引入了資格跡 (Eligibility Traces,  $E_t$ ) 的概念。傳統的 SARSA (即  $\lambda = 0$ ) 每次只更新前一步的 Q 值，屬於「短視」的更新；而 SARSA( $\lambda$ ) 則允許獎勵向後傳遞給過去一連串導致當前狀態的動作。

在我們的賣股任務中，這一點特別重要。假設代理人連續「持有」了 20 天，並在第 21 天「賣出」獲得高額報酬。傳統 SARSA 需要重複經歷非常多次這個過程，才能慢慢將第 21 天的獎勵一步步傳回第 1 天；而 SARSA( $\lambda$ ) 能透過資格跡，在一次賣出後，立即更新過去這 20 天所有「持有」決策的價值，大幅提升學習效率。

**核心機制：資格跡 (Eligibility Traces)**

我們為每一個狀態-動作對  $(s, x)$  維護一個變數  $E(s, x)$ 。

- 當代理人訪問  $(s_t, x_t)$  時， $E(s_t, x_t)$  會增加 (通常加 1)。
- 隨著時間推移，所有  $E(s, x)$  會以  $\gamma\lambda$  的速率衰減。
- 更新時，不只更新當前的 Q 值，而是按  $E(s, x)$  的比例更新所有走過的狀態。

## SARSA( $\lambda$ ) 更新公式：

首先計算 TD 誤差 (TD Error,  $\delta_t$ )：

$$\delta_t = r_{t+1} + \gamma Q(s_{t+1}, x_{t+1}) - Q(s_t, x_t)$$

接著更新所有狀態的 Q 值與資格跡：

$$E_t(s, x) \leftarrow \gamma \lambda E_{t-1}(s, x) + 1(s = s_t, x = x_t)$$

$$Q(s, x) \leftarrow Q(s, x) + \alpha \delta_t E_t(s, x)$$

最佳賣點任務的 SARSA( $\lambda$ ) 更新規則同樣依據是否賣出分為兩種情況：

情況 A：當  $x_t = \text{Hold}$

1. 計算誤差： $\delta_t = 0 + 1 \cdot Q(s_{t+1}, x_{t+1}) - Q(s_t, \text{Hold})$
2. 增加當前狀態的資格跡： $E(s_t, \text{Hold}) \leftarrow E(s_t, \text{Hold}) + 1$
3. 更新所有  $(s, x)$  的 Q 值： $Q(s, x) \leftarrow Q(s, x) + \alpha \delta_t E(s, x)$
4. 衰減所有資格跡： $E(s, x) \leftarrow 1 \cdot \lambda \cdot E(s, x)$

情況 B：當  $x_t = \text{Sell}$

1. 計算誤差： $\delta_t = C(S_t, \text{Sell}) + 0 - Q(s_t, \text{Sell})$  (賣出即終止，未來價值為0)
2. 增加當前狀態的資格跡： $E(s_t, \text{Sell}) \leftarrow E(s_t, \text{Sell}) + 1$
3. 更新所有  $(s, x)$  的 Q 值： $Q(s, x) \leftarrow Q(s, x) + \alpha \delta_t E(s, x)$
4. 因為 Episode 結束，重置所有  $E(s, x) = 0$ ，準備下一回合。

其中：

- $\lambda \in [0, 1]$ ：衰減因子。 $\lambda = 0$  即為傳統 SARSA； $\lambda = 1$  類似於蒙地卡羅方法 (Monte Carlo)，等到結局才算總帳。
- $E(s, x)$ ：紀錄某個狀態動作對在近期被訪問的頻率與時間遠近。

## 五. 實戰

### 回測環境設定

a. 選取資產：上市台股1000檔

b. 最大回測時間：2000-01-04 ~ 2025-11-19

c. 賣出規則：在測試期間的T天內，可以根據至第t天之前的資訊判斷，並且以隔日第t+1天的價格賣出。

d. RL方法：QL、SARSA、SARSA( $\lambda$ )，隨機來源使用BM、fBM(-f)。

e. 比較對象：基礎策略，B&H、、；以及技術指標，MA、KD、RSI、MACD、。

f. 回測方法：採用時間序列之拔靴法(bootstrap methods for time series) (Haruiv,2017; Efron & Tibshirani,1993)

**補充：**

B&amp;H：買入持有，最後一天賣出

🔍：隨機挑一天賣出

💰：第一天賣出股票存銀行，賺取利息。

MA：若短天期均線( $n=5$ ) < 長天期均線( $n=20$ )，賣出KD：若K線 < D線( $n=9$ )，賣出RSI：rsi值( $n=14$ ) > 70 表示股票過熱，賣出MACD：macd柱狀圖( $12,26,9$ ) < 0，賣出

**時間序列之拔靴法：**隨機挑選一支股票的一段連續時間(例如500天)當作訓練資料，並且在接下來的100天(也就是第501~600天)作為測試資料，用以比較各種方法的績效。此方法可在保留時間相依結構的情況下進行重抽樣，能夠降低單一樣本區間可能導致的樣本偏誤，提升績效結果的可靠性。

-0.0027142710678186065 0.03190366782002177

**實驗1. 100天賣股**

- $e_t$ : 參考近3期的股票報酬，使用標準差法離散化為5個區塊
- $M_t$ : 使用百分位數法離散為9個區塊
- $\alpha$  : 0.1
- $\gamma$  : 0.85
- $\epsilon$  : 0.2
- $\lambda$  : 0.4
- RL訓練次數為狀態數量的10倍
- 測試100天
- 訓練長度為測試的7倍
- 總共960次的測試

**實際報酬比較**

| 統計量   | QL       | SARSA   | SARSA( $\lambda$ ) | B&H      | 🔍        | MA      | KD      | RSI     | MACD    | 💰       | QLf     |
|-------|----------|---------|--------------------|----------|----------|---------|---------|---------|---------|---------|---------|
| count | 960      | 960     | 960                | 960      | 960      | 960     | 960     | 960     | 960     | 960     | 960     |
| mean  | 3.17%    | 1.52%   | 2.81%              | 7.39%    | 4.52%    | 1.39%   | 0.91%   | 2.92%   | 1.48%   | 0.79%   | 1.85%   |
| std   | 41.87%   | 7.80%   | 39.66%             | 50.98%   | 43.98%   | 6.77%   | 6.88%   | 21.89%  | 7.34%   | 2.95%   | 7.73%   |
| min   | -50.07%  | -41.04% | -40.94%            | -56.60%  | -56.11%  | -28.33% | -49.97% | -56.60% | -30.95% | -49.55% | -50.07% |
| 25%   | 0.23%    | 0.06%   | 0.26%              | -9.76%   | -6.25%   | -1.03%  | -2.11%  | -6.47%  | -1.16%  | -0.23%  | 0.21%   |
| 50%   | 1.91%    | 1.96%   | 2.40%              | 0.75%    | 0.71%    | 0.79%   | 0.70%   | 0.56%   | 0.79%   | 0.79%   | 2.07%   |
| 75%   | 4.40%    | 4.43%   | 5.13%              | 13.39%   | 8.87%    | 2.84%   | 3.12%   | 7.67%   | 2.91%   | 1.70%   | 4.60%   |
| max   | 1277.35% | 35.67%  | 1199.03%           | 1277.46% | 1183.17% | 74.94%  | 60.35%  | 247.87% | 79.83%  | 10.85%  | 32.79%  |

**報酬排名比較**

| 統計量   | QL   | SARSA | SARSA( $\lambda$ ) | B&H  | ?    | MA   | KD   | RSI  | MACD | 👛    | QLf  | SARSAf | SARSA( $\lambda$ )f |
|-------|------|-------|--------------------|------|------|------|------|------|------|------|------|--------|---------------------|
| count | 960  | 960   | 960                | 960  | 960  | 960  | 960  | 960  | 960  | 960  | 960  | 960    | 960                 |
| mean  | 5.20 | 5.28  | 5.25               | 6.79 | 7.14 | 7.44 | 7.96 | 7.25 | 7.41 | 7.89 | 4.98 | 5.24   | 5.37                |
| std   | 2.95 | 3.14  | 3.32               | 4.98 | 4.55 | 3.59 | 3.49 | 4.52 | 3.57 | 3.91 | 2.94 | 3.07   | 3.39                |
| min   | 1    | 1     | 1                  | 1    | 1    | 1    | 1    | 1    | 1    | 1    | 1    | 1      | 1                   |
| 25%   | 3    | 3     | 3                  | 1    | 3    | 4    | 5    | 2    | 4    | 5    | 3    | 3      | 3                   |
| 50%   | 5    | 5     | 5                  | 7    | 8    | 8    | 9    | 8    | 8    | 9    | 5    | 5      | 5                   |
| 75%   | 7    | 7     | 8                  | 12   | 12   | 10   | 11   | 12   | 10   | 11   | 7    | 7      | 8                   |
| max   | 13   | 13    | 13                 | 13   | 13   | 13   | 13   | 13   | 13   | 13   | 13   | 13     | 13                  |

## 結果分析-實驗1(100天)

以下歸納RL方法在本實驗中的核心優勢。

### 1. 壓倒性的中位數表現（勝率的保證）

中位數（Median）代表了策略在「大多數情況下」的表現。這是 RL 方法最強大的護城河。

- RL 完勝 B&H：
  - B&H 中位數僅 0.75%，這意味著有一半的時間，買入持有策略的獲利微乎其微，甚至不如銀行利息（0.79%）。
  - RL 方法（如 QLf, SARSA( $\lambda$ )) 中位數高達 2.07%~2.40%。
  - 結論：在隨機的市場波動中，RL 策略能穩定地創造出 比 B&H 高出近 3 倍 的中位數回報。這證明了 RL 能夠有效過濾無效波動，在有獲利時果斷落袋。

### 2. 排名穩定性居冠

從報酬排名（Rank）來看，RL 是表現最穩定的策略群體。

- 平均排名第一：
  - QLf (使用 fBM 訓練) 取得了全場最佳的平均排名 4.98，是唯一平均排名進入前 5 名的策略。
  - 相比之下，B&H 平均排名為 6.79，MA 為 7.44，KD 為 7.96。
- 穩定的前段班：
  - RL 方法的排名標準差（Std）顯著低於 B&H，且中位數排名穩定維持在 5。這代表 RL 策略極少墊底，無論市場好壞，它都能維持在所有策略的前半段。

## 實驗2. 30天賣出

- $e_t$ : 參考近3期的股票報酬，使用標準差法離散化為5個區塊
- $M_t$ : 使用百分位數法離散為9個區塊
- $\alpha$ : 0.1
- $\gamma$ : 0.85
- $\epsilon$ : 0.2
- $\lambda$ : 0.4



- RL訓練次數為狀態數量的10倍
- 測試30天
- 訓練長度為測試的7倍
- 總共960次的測試

## 實際報酬比較

| 統計量   | QL      | SARSA   | SARSA( $\lambda$ ) | B&H     | ?       | MA      | KD      | RSI     | MACD    | 💰      | QLf     | S       |
|-------|---------|---------|--------------------|---------|---------|---------|---------|---------|---------|--------|---------|---------|
| count | 960     | 960     | 960                | 960     | 960     | 960     | 960     | 960     | 960     | 960    | 960     | 960     |
| mean  | 0.47%   | 0.64%   | 0.68%              | 1.89%   | 1.36%   | 0.76%   | 0.48%   | 1.54%   | 0.78%   | 0.25%  | 0.33%   | 0.47%   |
| std   | 7.89%   | 8.00%   | 8.88%              | 16.31%  | 11.92%  | 7.19%   | 5.34%   | 15.16%  | 6.35%   | 2.30%  | 8.18%   | 8.18%   |
| min   | -40.82% | -40.26% | -40.26%            | -40.81% | -40.81% | -50.69% | -49.29% | -40.81% | -50.69% | -9.79% | -40.82% | -40.82% |
| 25%   | -0.83%  | -0.68%  | -1.28%             | -6.08%  | -3.40%  | -1.63%  | -1.38%  | -5.38%  | -1.32%  | -0.69% | -1.15%  | -1.15%  |
| 50%   | 1.03%   | 1.00%   | 1.51%              | 0.01%   | 0.10%   | 0.22%   | 0.21%   | 0.01%   | 0.23%   | 0.24%  | 1.04%   | 1.04%   |
| 75%   | 3.64%   | 3.69%   | 4.58%              | 6.73%   | 3.95%   | 1.97%   | 2.00%   | 5.39%   | 2.03%   | 1.05%  | 3.55%   | 3.55%   |
| max   | 39.91%  | 39.91%  | 39.91%             | 97.92%  | 85.42%  | 82.84%  | 49.74%  | 96.62%  | 43.73%  | 11.59% | 39.91%  | 85.42%  |

## 報酬排名比較

| 統計量   | QL   | SARSA | SARSA( $\lambda$ ) | B&H  | ?    | MA   | KD   | RSI  | MACD | 💰    | QLf  | SARSAf | SARSA( $\lambda$ )f |
|-------|------|-------|--------------------|------|------|------|------|------|------|------|------|--------|---------------------|
| count | 960  | 960   | 960                | 960  | 960  | 960  | 960  | 960  | 960  | 960  | 960  | 960    | 960                 |
| mean  | 5.48 | 5.50  | 5.45               | 6.32 | 7.30 | 7.05 | 7.19 | 6.57 | 6.89 | 7.48 | 5.63 | 5.50   | 5.46                |
| std   | 3.10 | 3.09  | 3.29               | 4.34 | 4.12 | 3.81 | 3.72 | 4.24 | 3.69 | 4.23 | 3.15 | 3.16   | 3.33                |
| min   | 1    | 1     | 1                  | 1    | 1    | 1    | 1    | 1    | 1    | 1    | 1    | 1      | 1                   |
| 25%   | 3    | 3     | 3                  | 1    | 3    | 3    | 4    | 2    | 3    | 4    | 3    | 3      | 3                   |
| 50%   | 5    | 5     | 5                  | 6.5  | 8    | 7    | 8    | 7    | 7    | 9    | 5    | 5      | 5                   |
| 75%   | 8    | 8     | 8                  | 11   | 11   | 11   | 10   | 11   | 10   | 11   | 8    | 8      | 8                   |
| max   | 13   | 13    | 13                 | 13   | 13   | 13   | 13   | 13   | 13   | 13   | 13   | 13     | 13                  |

## 結果分析-實驗2(30天)

即使賣出天數調降至30天(短天期)，RL賣出方法的中位數優勢依舊存在，排名的平均還比B&H少了0.81，也就是說RL是穩穩賺錢的好方法。

## 實驗3. 100天賣出，強化版TA

參數設定和實驗1相同，但是強化了技術分析(TA)的賣出邏輯，賣出方法調整如下：

- MA：慢線 < 快線  $\Rightarrow$  慢線由上往下穿越快線死亡交叉
- RSI：rsi > 70  $\Rightarrow$  昨天 > 70 且 今天 < 70

- KD：K值 < D值  $\Rightarrow$  高檔鈍化(K值>80)後死叉
- MACD：macd柱狀體 < 0  $\Rightarrow$  昨天hist > 0 且 今天 hist < 0

## 實際報酬比較

| 統計量   | QL      | SARSA   | SARSA( $\lambda$ ) | B&H     | ?       | MA      | KD      | RSI     | MACD    | 💰      | QLf     |
|-------|---------|---------|--------------------|---------|---------|---------|---------|---------|---------|--------|---------|
| count | 960     | 960     | 960                | 960     | 960     | 960     | 960     | 960     | 960     | 960    | 960     |
| mean  | 1.78%   | 2.05%   | 2.26%              | 5.40%   | 3.37%   | 2.61%   | 3.45%   | 3.45%   | 2.05%   | 0.85%  | 1.96%   |
| std   | 8.66%   | 8.72%   | 9.82%              | 28.66%  | 19.08%  | 15.72%  | 23.17%  | 22.33%  | 14.90%  | 2.37%  | 9.25%   |
| min   | -50.38% | -42.94% | -48.12%            | -53.95% | -47.12% | -38.81% | -52.45% | -53.95% | -44.80% | -9.29% | -50.38% |
| 25%   | 0.07%   | 0.07%   | 0.70%              | -10.80% | -6.01%  | -4.22%  | -6.72%  | -7.05%  | -4.31%  | -0.20% | 0.12%   |
| 50%   | 1.95%   | 2.00%   | 2.58%              | 0.46%   | 0.79%   | 0.64%   | 0.96%   | 0.69%   | 0.68%   | 0.79%  | 1.96%   |
| 75%   | 4.32%   | 4.69%   | 5.29%              | 14.35%  | 8.77%   | 6.28%   | 8.89%   | 8.33%   | 5.34%   | 1.73%  | 4.20%   |
| max   | 76.78%  | 95.19%  | 105.53%            | 243.40% | 147.11% | 204.34% | 243.40% | 207.97% | 208.39% | 12.03% | 102.01% |

## 報酬排名比較

| 統計量   | QL   | SARSA | SARSA( $\lambda$ ) | B&H  | ?    | MA   | KD   | RSI  | MACD | 💰    | QLf  | SARSAf | SARSA( $\lambda$ )f |
|-------|------|-------|--------------------|------|------|------|------|------|------|------|------|--------|---------------------|
| count | 960  | 960   | 960                | 960  | 960  | 960  | 960  | 960  | 960  | 960  | 960  | 960    | 960                 |
| mean  | 5.56 | 5.44  | 5.40               | 6.67 | 7.10 | 7.24 | 6.86 | 7.00 | 7.45 | 8.04 | 5.49 | 5.54   | 5.55                |
| std   | 3.09 | 3.03  | 3.16               | 4.71 | 4.15 | 3.90 | 4.21 | 4.17 | 3.77 | 4.03 | 3.07 | 3.08   | 3.25                |
| min   | 1    | 1     | 1                  | 1    | 1    | 1    | 1    | 1    | 1    | 1    | 1    | 1      | 1                   |
| 25%   | 3    | 3     | 3                  | 1    | 3    | 4    | 3    | 3    | 4    | 5    | 3    | 3      | 3                   |
| 50%   | 5    | 5     | 5                  | 7    | 7.5  | 8    | 8    | 8    | 8    | 9    | 5    | 5      | 5                   |
| 75%   | 8    | 8     | 7                  | 11   | 11   | 11   | 11   | 11   | 11   | 12   | 8    | 8      | 8                   |
| max   | 13   | 13    | 13                 | 13   | 13   | 13   | 13   | 13   | 13   | 13   | 13   | 13     | 13                  |

## 另一組參數設計

- $e_t$ : 參考近7期的股票報酬，使用標準差法離散化為2個區塊
- $M_t$ : 使用百分位數法離散為2個區塊
- $\alpha$ : 0.1
- $\gamma$ : 0.85
- $\epsilon$ : 0.25
- $\lambda$ : 0.25
- RL訓練次數為狀態數量的10倍
- 測試100天
- 訓練長度為測試的6倍
- 總共960次的測試

100%|██████████| 960/960 [05:09&lt;00:00, 3.10it/s]

# SARSA: (-1.53,-1.33) | (7, 2, 2) = 256, ((0.1, 0.85, 0.25, 0.25)), len=6

實際報酬比較

|           | QL        | SARSA     | SARSA( $\lambda$ ) | B&H       | ?                   | MA        | KD        | R         |
|-----------|-----------|-----------|--------------------|-----------|---------------------|-----------|-----------|-----------|
| SI        | MACD      | 👉         | QLf                | SARSAf    | SARSA( $\lambda$ )f |           |           |           |
| count     | 96000.00% | 96000.00% | 96000.00%          | 96000.00% | 96000.00%           | 96000.00% | 96000.00% | 96000.00% |
| 96000.00% | 96000.00% | 96000.00% | 96000.00%          | 96000.00% | 96000.00%           |           |           |           |
| mean      | 2.21%     | 2.43%     | 2.41%              | 7.17%     | 3.85%               | 2.97%     | 4.03%     | 4.73%     |
| 2.40%     | 0.82%     | 2.13%     | 2.31%              | 2.12%     |                     |           |           |           |
| std       | 10.38%    | 10.19%    | 10.34%             | 37.40%    | 21.39%              | 15.70%    | 25.10%    | 26.90%    |
| 13.62%    | 2.48%     | 10.35%    | 10.11%             | 10.51%    |                     |           |           |           |
| min       | -57.84%   | -57.84%   | -57.84%            | -73.40%   | -69.43%             | -49.02%   | -71.78%   | -71.47%   |
| -49.02%   | -9.24%    | -57.84%   | -57.60%            | -56.68%   |                     |           |           |           |
| 25%       | -0.18%    | -0.11%    | -0.03%             | -8.95%    | -5.78%              | -3.35%    | -6.47%    | -6.32%    |
| -3.09%    | -0.15%    | -0.22%    | -0.02%             | -0.20%    |                     |           |           |           |
| 50%       | 2.61%     | 2.68%     | 2.76%              | 0.72%     | 0.90%               | 1.14%     | 0.68%     | 0.98%     |
| 1.07%     | 0.79%     | 2.60%     | 2.57%              | 2.75%     |                     |           |           |           |
| 75%       | 5.85%     | 5.98%     | 6.29%              | 14.74%    | 8.15%               | 5.93%     | 9.28%     | 9.39%     |
| 5.13%     | 1.66%     | 5.82%     | 5.92%              | 5.93%     |                     |           |           |           |
| max       | 53.19%    | 53.19%    | 53.19%             | 516.72%   | 153.76%             | 229.17%   | 271.99%   | 331.93%   |
| 140.86%   | 10.87%    | 53.19%    | 62.79%             | 53.19%    |                     |           |           |           |

報酬排名比較

|       | QL     | SARSA               | SARSA( $\lambda$ ) | B&H    | ?      | MA     | KD     | RSI    | MACD   | 👉      |
|-------|--------|---------------------|--------------------|--------|--------|--------|--------|--------|--------|--------|
| QLf   | SARSAf | SARSA( $\lambda$ )f |                    |        |        |        |        |        |        |        |
| count | 960.00 | 960.00              | 960.00             | 960.00 | 960.00 | 960.00 | 960.00 | 960.00 | 960.00 | 960.00 |
| 0     | 960.00 | 960.00              |                    |        |        |        |        |        |        |        |
| mean  | 5.41   | 5.19                | 5.32               | 6.72   | 7.30   | 7.31   | 6.95   | 6.95   | 7.56   | 8.08   |
| 3     | 5.43   | 5.56                |                    |        |        |        |        |        |        |        |
| std   | 3.10   | 3.08                | 3.17               | 4.72   | 4.12   | 3.74   | 4.18   | 4.21   | 3.68   | 4.21   |
| 5     | 3.23   | 3.23                |                    |        |        |        |        |        |        |        |
| min   | 1.00   | 1.00                | 1.00               | 1.00   | 1.00   | 1.00   | 1.00   | 1.00   | 1.00   | 1.00   |
| 0     | 1.00   | 1.00                |                    |        |        |        |        |        |        |        |
| 25%   | 3.00   | 3.00                | 3.00               | 1.00   | 3.00   | 4.00   | 3.00   | 3.00   | 4.00   | 5.00   |
| 0     | 3.00   | 3.00                |                    |        |        |        |        |        |        |        |
| 50%   | 5.00   | 5.00                | 5.00               | 8.00   | 8.00   | 8.00   | 8.00   | 8.00   | 8.00   | 9.00   |
| 0     | 5.00   | 5.00                |                    |        |        |        |        |        |        |        |
| 75%   | 7.00   | 7.00                | 7.00               | 11.00  | 11.00  | 10.00  | 11.00  | 11.00  | 11.00  | 12.00  |
| 0     | 7.00   | 8.00                |                    |        |        |        |        |        |        |        |
| max   | 13.00  | 13.00               | 13.00              | 13.00  | 13.00  | 13.00  | 13.00  | 13.00  | 13.00  | 13.00  |
| 0     | 13.00  | 13.00               |                    |        |        |        |        |        |        |        |

## 結果分析-實驗3(100天，強化TA)

強化TA比原本的簡單TA好很多，平均報酬還有排名都到了能夠與隨機賣出一較高下的地步，但是RL的中位數以及排名仍然大幅輾壓這些基本、技術分析的方法。因此使用技術分析，不如長期持有或是用這裡的RL方法。

## 六. 結論與未來展望

本文使用三種RL方法，Q-learning、SARSA、SARSA( $\lambda$ )來自動選擇最佳的賣股時機點，並且使用時間序列的拔靴法進行回測。與基本和技術分析方法比較，在中位數、Q1報酬以及報酬排名上大幅領先，表示RL能夠穩定的賺取報酬，取得了漂亮的成就。

未來可以嘗試reward改成別的績效指標，例如Sharpe或是Utility函數。或是不要一次賣出股票，動作可以換成一次賣出一部份的股票，讓操作更符合實務。

## 七.參考文獻

Corazza, M., & Sangalli, A. (2015). Q-learning and SARSA: A comparison between two intelligent stochastic control approaches for financial trading (Working Paper No. 15/WP/2015). Department of Economics, Ca' Foscari University of Venice.

Efron, B., & Tibshirani, R. J. (1993). An introduction to the bootstrap. New York, NY: Chapman & Hall/CRC.

Haruvi, Y. (2017). Applying bootstrap methods to time series and regression models. M.Sc. Seminar in Statistics, Tel Aviv University.

Powell, W. B. (2022). Reinforcement learning and stochastic optimization: A unified framework for sequential decisions. Hoboken, NJ: John Wiley & Sons.