

目錄

1. 摘要
2. 馬可夫決策框架
3. 賣股問題模型設計
4. 強化學習策略設計
5. 實戰
6. 結論與未來展望
7. 參考文獻

一. 摘要

股票市場有一句名言「會買的是徒弟，會賣的才是師父」，賣股的時機一直是讓投資人頭痛的問題。為了解決這個難題，本研究以量化的角度將其包裝成馬可夫決策過程 (Markov Decision Process, MDP)。透過各種的強化學習方法(Reinforcement Learning policy)：SARSA、Q-learning、SARSA(λ)，設計出賣股策略，目標是提升投資績效。

最佳賣點問題：

1. 問題建模 (Problem Formulation)：

將股票交易中的賣出時機選擇問題，正式定義為一個馬可夫決策過程 (MDP)，使決策過程具備數學上的嚴謹性。

2. 演算法應用 (Methodology)：

採用強化學習 (Reinforcement Learning) 中的 SARSA、Q-learning 以及 SARSA(λ) 演算法，訓練代理人 (Agent) 學習在動態市場環境下的最佳決策。

3. 最佳賣點任務 (Task Definition)：

- 限制條件：投資人必須在未來 T 天的時間窗口內，賣出手中的一支股票。(最晚會在第 T 天強制賣出)
- 報酬計算：考量「機會成本」與「時間價值」，將賣股所得與後續存入銀行的利息總和納入考量。

4. 研究目標 (Objective)：

比較不同策略的表現，旨在設計出一套能顯著提升投資績效的最佳賣股策略。

二. 馬可夫決策框架

參考Powell(2022)，馬可夫決策過程(MDP)有五個核心的要素(Powell Framework)，分別是狀態變數、決策變數、外生資訊、狀態轉移函數以及目標函數，以下分別介紹基本概念。

1. 狀態變數 (State Variables, S_t)

狀態變數代表了在時間點 t 做決策時所擁有的「所有知識與資訊」的集合。根據 Powell 的定義，狀態變數必須具備馬可夫性質 (Markov Property)，即包含所有計算決策及推導下一個狀態所需的必要資訊。 S_t 通常包含以下三類資訊：物理狀態 (Physical State)：例如庫存量、位置、資金餘額等具體資源。資訊狀態 (Information State)：例如當前的市場價格、天氣數據等外在環境數據。信念狀態 (Belief State)：當系統包含不確定參數時 (例如未知的需求分佈參數)，我們對這些參數的主觀機率分佈或估計值。

2. 決策變數 (Decision Variables, x_t)

決策變數是在時間點 t ，根據當前狀態 S_t 所採取的行動或控制量。在強化學習中常被稱為 Action (a_t)。決策必須受到限制條件 (Constraints) 的約束，我們通常用 $\mathcal{X}_t$ 來表示在時間 t 的可行決策集合，因此：

$$x_t \in \mathcal{X}_t$$

決策的產生通常依賴於一個策略 (Policy)，記為 π ，即 $x_t = X^\pi(S_t)$ 。我們的目標就是找到一個表現最好的函數 π 。

3. 外生資訊 (Exogenous Information, W_{t+1})

這是在我們做出決策 x_t 之後，但在時間 $t + 1$ 之前首次得知的新資訊。這是系統隨機性 (Stochasticity) 的來源。這些資訊可能包括：隨機的需求變化。資產價格的波動。系統的隨機故障或延遲。在數學上，我們通常假設 W_{t+1} 是一個隨機變數，其分佈可能依賴於當前的狀態 S_t 。

4. 狀態轉移函數 (Transition Function, S^M)

狀態轉移函數描述了系統如何從時間 t 演變到時間 $t + 1$ 。它是連結狀態、決策與外生資訊的數學模型。不同於傳統 MDP 教科書有時使用轉移矩陣 (Transition Matrix)，Powell 架構強調使用顯式的方程形式：

$$S_{t+1} = S^M(S_t, x_t, W_{t+1})$$

這個函數 $S^M(\cdot)$ 包含了所有的物理守恆定律、邏輯規則或市場演變公式。例如：庫存更新公式 $R_{t+1} = R_t - x_t + \hat{D}_{t+1}$ (其中 $\hat{D}$ 為隨機需求)。

5. 目標函數 (Objective Function)

目標函數用來評估我們決策的好壞。通常由兩部分組成：貢獻/成本函數 (Contribution/Cost Function, $C(S_t, x_t)$)：單期決策帶來的立即收益或成本。期望值 (Expectation)：因為未來充滿不確定性 (由 W 造成)，我們追求的是最大化累積獎勵的期望值。數學上，我們的目標是尋找最佳策略 π^* 來最大化總價值：

$$\max_{\pi} \mathbb{E} \left[\sum_{t=0}^T \gamma^t C(S_t, X^\pi(S_t)) \right]$$

其中 γ 為折現因子 (Discount Factor)。

三. 賣股問題模型設計

本研究在交易策略設計上參考強化學習於金融交易之應用文獻，特別是比較 Q-learning 與 SARSA 的表現 (Corazza & Sangalli, 2015)，並結合隨機最佳化與序列決策之理論架構 (Powell, 2022)，將「股票最佳

賣出時點選擇」問題建構為一個有限期時序決策問題(Finite-horizon sequential decision-making problem)，以下為設計的Powell Framework

1. 狀態變數 (State Variables, S_t)

$$S_t = (e_{t-\ell}, e_{t-(\ell-1)}, \dots, e_{t-1}, e_t, M_t)$$

- t : 目前的時間期數, $t = 0 \sim T$
- e_t : t 時間點的對數報酬(log return), $e_t = \log \frac{P_t}{P_{t-1}}$
- M_t : t 時間點時相對於期初的對數報酬, $M_t = \log \frac{P_t}{P_0}$
- 賣出的話, $S_t = \emptyset$ (terminal state)

如果是均值回歸的信者, 當發現過去一段時間股價報酬一直創新高會考慮賣股; 趨勢交易者發現股價向下突破某一閾值也會考慮賣股。狀態變數的設計考慮了這兩種情況, 因此將一段時間之前的對數報酬(近期報酬)以及目前的總報酬率(長期報酬)考慮進來, 期望擁有更全面的判斷能力。

離散化方法：分位數分箱 (Quantile Binning)

由於 e_t 和 M_t 報酬率都是連續變數, 對於建立Q-table非常不利, 因此我們需要離散化狀態變數。

- 邏輯：將歷史(模擬)資料(單期報酬、累積報酬)切成 n 等份, 再把當前的報酬分配到對應的區間內。
- 特色：不管資料分佈多麼不均勻 (例如極端值很多), 每個箱子裡的資料筆數是一樣多的, 能夠適應不同股價的性質。
- 例子：假設 $n_1 = 4$ (把單期報酬切成 4 等份), 它會找出 25%、50%、75% 的位置當作切點 (Cut-offs), $n_2 = 5$ (把累積報酬切成5等分), 考慮2天的近期報酬。則狀態數目就只剩下 $5 * 4^2$

2. 決策變數 (Decision Variables, x_t)

在尚未賣出且未達到投資期限的情況下, 投資者可以選擇明天($t + 1$)要賣出(Sell)或是繼續 持有(Hold), 但在最後一天 T 時, 必須強制賣出。在任何時間點賣出, 系統都會進入終止狀態(terminal state)

$$x_t = X_t(S_t) = \begin{cases} \{\text{Hold, Sell}\}, & x_{t-1} = \text{Hold} \\ \text{Sell}, & t = T - 1 \end{cases}$$

3. 外生資訊 (Exogenous Information, W_{t+1})

外生資訊定義為驅動股價變動的隨機變數, 可以來自於布朗運動(BM)、碎形布朗運動(fBM)、Heston Model等。

定義 $t + 1$ 時刻的外生資訊向量為：

$$W_{t+1} = Z_{t+1}$$

假如選用BM於模擬環境中, Z_{t+1} 就是標準常態分配變數, 即 $Z_{t+1} \sim N(0, 1)$

4. 狀態轉移函數 (Transition Function, S^M)

我們的狀態是由股價來計算組成, 因此股價狀態的更新能夠代表狀態轉移函數。針對不同的價格隨機模型, 股價的轉移方程也有所不同：

$$P_{t+1} = f(P_t)$$

- $f()$ ：股價隨機過程，例如BM：

$$P_{t+1} = P_t \cdot \exp\left(\left(\mu - \frac{\sigma^2}{2}\right) \Delta t + \sigma \sqrt{\Delta t} Z_{t+1}\right)$$

其中， μ ：預期報酬率 (Drift) σ ：波動率 (Volatility) Δt ：時間間隔 Z_{t+1} ：來自外生資訊 W_{t+1} 的隨機項

配合前述的狀態變數 S_t ，其餘變數（如單期報酬 e_t 、累積報酬 M_t ）亦隨之更新：

$$S_{t+1} = \begin{cases} M_{t+1} = \log \frac{P_{t+1}}{P_0}, e_{t+1} = \log \frac{P_{t+1}}{P_t} & x_t = \text{Hold} \\ \emptyset, & x_t = \text{Sell} \end{cases}$$

5. 目標函數 (Objective Function)

本研究的目標是在有限期限 T 天內，選擇最佳賣出時點，讓期望累積報酬率最大化。

- 選擇持有，則當期不產生即時報酬
- 如果在第 τ 天賣出，所得到的現金 P_τ 會投入銀行並以無風險利率 r_f 滾存到第 T 天

Contibution Function(累積報酬率)

$$C(S_t, x_t) = \begin{cases} 0, & x_t = \text{Hold} \\ \frac{P_{t+1}(1+r_f)^{T-t-1}}{P_0} - 1, & x_t = \text{Sell} \end{cases}$$

最佳策略 π^*

$$\max_{\pi} \mathbb{E} \left[\sum_{t=0}^T C(S_t, X^{\pi}(S_t)) \right]$$

由於任務定義已經考慮了無風險利率報酬的時間成本，所以目標函數不再設計折現率 γ 。

四. 強化學習策略設計

1. SARSA

SARSA 為一種在策略 (On-policy) 的時間差分 (Temporal-Difference, TD) 學習演算法。其核心特點在於：代理人 (agent) 在更新狀態-動作價值時，必須依據實際所採取的動作進行更新，而非假設未來一定會選擇最佳動作。SARSA 在學習過程中，行為策略 (behavior policy) 與被評估的策略 (target policy) 是相同的。代理人根據當前策略 (通常為 ϵ -greedy) 選擇動作，並且在更新 Q 值時，使用「下一狀態中實際選擇的動作」所對應的 Q 值進行更新。因此，SARSA 能夠忠實反映探索行為對學習過程的影響。

SARSA更新公式 (使用實際採取的 x_{t+1})：

$$Q(s_t, x_t) = Q(s_t, x_t) + \alpha[r_{t+1} + \gamma Q(s_{t+1}, x_{t+1}) - Q(s_t, x_t)]$$

註：這裡的 x_{t+1} 是代理人實際會去執行的動作。

最佳賣點任務的SARSA更新規則可以分成兩種情況：

情況 A：當 $x_t = \text{Hold}$

$$Q(s_t, \text{Hold}) \leftarrow Q(s_t, \text{Hold}) + \alpha[0 + 1 \cdot Q(s_{t+1}, x_{t+1}) - Q(s_t, \text{Hold})]$$

(這裡 $\gamma = 1$ 配合 contribution function C 的設計，獎勵是 0)

情況 B：當 $x_t = \text{Sell}$

$$Q(s_t, \text{Sell}) \leftarrow Q(s_t, \text{Sell}) + \alpha[C(S_t, \text{Sell}) + 0 - Q(s_t, \text{Sell})]$$

(因為賣出後遊戲結束，沒有下一期的 Q 值)

其中：

- $\alpha \in (0, 1]$ ：學習率 (learning rate)，控制每次更新對舊 Q 值的影響程度
- $Q(s, x)$ ：狀態-動作對應的 Q 值

2. Q-learning

Q-Learning 為一種離策略 (Off-policy) 學習演算法。其特點在於：代理人 (agent) 在更新狀態-動作價值時，不依賴實際執行的動作，而是根據「在下一個狀態中能使 Q 值最大的動作」來進行更新。

換言之，Q-Learning 在學習過程中，行為策略 (behavior policy) 與被評估的策略 (target policy) 是不同的。即使代理人因探索而執行了非最佳動作，更新時仍假設未來會選擇最佳行動。

Q-learning 更新公式 (使用理論最佳的 $\max x'$)：

$$Q(s_t, x_t) = Q(s_t, x_t) + \alpha[r_{t+1} + \gamma \max_{x'} Q(s_{t+1}, x') - Q(s_t, x_t)]$$

註：這裡不管代理人實際上會做什麼，直接取最大值來更新。

最佳賣點任務的 Q-learning 更新規則也可以分成兩種情況：

情況 A：當 $x_t = \text{Hold}$

$$Q(s_t, \text{Hold}) \leftarrow Q(s_t, \text{Hold}) + \alpha[0 + 1 \cdot \max_{x'} Q(s_{t+1}, x') - Q(s_t, \text{Hold})]$$

情況 B：當 $x_t = \text{Sell}$

$$Q(s_t, \text{Sell}) \leftarrow Q(s_t, \text{Sell}) + \alpha[C(S_t, \text{Sell}) + 0 - Q(s_t, \text{Sell})]$$

3. SARSA(λ)

SARSA(λ) 是 SARSA 的改進版本，它引入了資格跡 (Eligibility Traces, E_t) 的概念。傳統的 SARSA (即 $\lambda = 0$) 每次只更新前一步的 Q 值，屬於「短視」的更新；而 SARSA(λ) 則允許獎勵向後傳遞給過去一連串導致當前狀態的動作。

在我們的賣股任務中，這一點特別重要。假設代理人連續「持有」了 20 天，並在第 21 天「賣出」獲得高額報酬。傳統 SARSA 需要重複經歷非常多次這個過程，才能慢慢將第 21 天的獎勵一步步傳回第 1 天；而 SARSA(λ) 能透過資格跡，在一次賣出後，立即更新過去這 20 天所有「持有」決策的價值，大幅提升學習效率。

核心機制：資格跡 (Eligibility Traces)

我們為每一個狀態-動作對 (s, x) 維護一個變數 $E(s, x)$ 。

- 當代理人訪問 (s_t, x_t) 時， $E(s_t, x_t)$ 會增加 (通常加 1)。
- 隨著時間推移，所有 $E(s, x)$ 會以 $\gamma\lambda$ 的速率衰減。
- 更新時，不只更新當前的 Q 值，而是按 $E(s, x)$ 的比例更新所有走過的狀態。

SARSA(λ) 更新公式：

首先計算 TD 誤差 (TD Error, δ_t)：

$$\delta_t = r_{t+1} + \gamma Q(s_{t+1}, x_{t+1}) - Q(s_t, x_t)$$

接著更新所有狀態的 Q 值與資格跡：

$$E_t(s, x) \leftarrow \gamma \lambda E_{t-1}(s, x) + 1(s = s_t, x = x_t)$$

$$Q(s, x) \leftarrow Q(s, x) + \alpha \delta_t E_t(s, x)$$

最佳賣點任務的 SARSA(λ) 更新規則同樣依據是否賣出分為兩種情況：

情況 A：當 $x_t = \text{Hold}$

1. 計算誤差： $\delta_t = 0 + 1 \cdot Q(s_{t+1}, x_{t+1}) - Q(s_t, \text{Hold})$
2. 增加當前狀態的資格跡： $E(s_t, \text{Hold}) \leftarrow E(s_t, \text{Hold}) + 1$
3. 更新所有 (s, x) 的 Q 值： $Q(s, x) \leftarrow Q(s, x) + \alpha \delta_t E(s, x)$
4. 衰減所有資格跡： $E(s, x) \leftarrow 1 \cdot \lambda \cdot E(s, x)$

情況 B：當 $x_t = \text{Sell}$

1. 計算誤差： $\delta_t = C(s_t, \text{Sell}) + 0 - Q(s_t, \text{Sell})$ (賣出即終止，未來價值為0)
2. 增加當前狀態的資格跡： $E(s_t, \text{Sell}) \leftarrow E(s_t, \text{Sell}) + 1$
3. 更新所有 (s, x) 的 Q 值： $Q(s, x) \leftarrow Q(s, x) + \alpha \delta_t E(s, x)$
4. 因為 Episode 結束，重置所有 $E(s, x) = 0$ ，準備下一回合。

其中：

- $\lambda \in [0, 1]$ ：衰減因子。 $\lambda = 0$ 即為傳統 SARSA； $\lambda = 1$ 類似於蒙地卡羅方法 (Monte Carlo)，等到結局才算總帳。
- $E(s, x)$ ：紀錄某個狀態動作對在近期被訪問的頻率與時間遠近。

五. 實戰

回測環境設定

a. 選取資產：上市台股1000檔

b. 最大回測時間：2000-01-04 ~ 2025-11-19

c. 賣出規則：在測試期間的T天內，可以根據至第t天之前的資訊判斷，並且以隔日第t+1天的價格賣出。

d. RL方法：QL、SARSA、SARSA(λ)，隨機來源使用BM、fBM(-f)。

e. 比較對象：基礎策略，B&H、、；以及技術指標，MA、KD、RSI、MACD、。

f. 回測方法：採用時間序列之拔靴法(bootstrap methods for time series) (Haruiv,2017; Efron & Tibshirani,1993)

補充：

B&H：買入持有，最後一天賣出

🔍：隨機挑一天賣出

💰：第一天賣出股票存銀行，賺取利息。

MA：若短天期均線($n=5$) < 長天期均線($n=20$)，賣出KD：若K線 < D線($n=9$)，賣出RSI：rsi值($n=14$) > 70 表示股票過熱，賣出MACD：macd柱狀圖($12,26,9$) < 0，賣出

時間序列之拔靴法：隨機挑選一支股票的一段連續時間(例如500天)當作訓練資料，並且在接下來的100天(也就是第501~600天)作為測試資料，用以比較各種方法的績效。此方法可在保留時間相依結構的情況下進行重抽樣，能夠降低單一樣本區間可能導致的樣本偏誤，提升績效結果的可靠性。

-0.0027142710678186065 0.03190366782002177

實驗1. 100天賣股

- e_t : 參考近3期的股票報酬，使用標準差法離散化為5個區塊
- M_t : 使用百分位數法離散為9個區塊
- α : 0.1
- γ : 0.85
- ϵ : 0.2
- λ : 0.4
- RL訓練次數為狀態數量的10倍
- 測試100天
- 訓練長度為測試的7倍
- 總共960次的測試

實際報酬比較

統計量	QL	SARSA	SARSA(λ)	B&H	🔍	MA	KD	RSI	MACD	💰	QLf
count	960	960	960	960	960	960	960	960	960	960	960
mean	3.17%	1.52%	2.81%	7.39%	4.52%	1.39%	0.91%	2.92%	1.48%	0.79%	1.85%
std	41.87%	7.80%	39.66%	50.98%	43.98%	6.77%	6.88%	21.89%	7.34%	2.95%	7.73%
min	-50.07%	-41.04%	-40.94%	-56.60%	-56.11%	-28.33%	-49.97%	-56.60%	-30.95%	-49.55%	-50.07%
25%	0.23%	0.06%	0.26%	-9.76%	-6.25%	-1.03%	-2.11%	-6.47%	-1.16%	-0.23%	0.21%
50%	1.91%	1.96%	2.40%	0.75%	0.71%	0.79%	0.70%	0.56%	0.79%	0.79%	2.07%
75%	4.40%	4.43%	5.13%	13.39%	8.87%	2.84%	3.12%	7.67%	2.91%	1.70%	4.60%
max	1277.35%	35.67%	1199.03%	1277.46%	1183.17%	74.94%	60.35%	247.87%	79.83%	10.85%	32.79%

報酬排名比較

統計量	QL	SARSA	SARSA(λ)	B&H	?	MA	KD	RSI	MACD	👛	QLf	SARSAf	SARSA(λ)f
count	960	960	960	960	960	960	960	960	960	960	960	960	960
mean	5.20	5.28	5.25	6.79	7.14	7.44	7.96	7.25	7.41	7.89	4.98	5.24	5.37
std	2.95	3.14	3.32	4.98	4.55	3.59	3.49	4.52	3.57	3.91	2.94	3.07	3.39
min	1	1	1	1	1	1	1	1	1	1	1	1	1
25%	3	3	3	1	3	4	5	2	4	5	3	3	3
50%	5	5	5	7	8	8	9	8	8	9	5	5	5
75%	7	7	8	12	12	10	11	12	10	11	7	7	8
max	13	13	13	13	13	13	13	13	13	13	13	13	13

結果分析-實驗1(100天)

以下歸納RL方法在本實驗中的核心優勢。

1. 壓倒性的中位數表現（勝率的保證）

中位數（Median）代表了策略在「大多數情況下」的表現。這是 RL 方法最強大的護城河。

- RL 完勝 B&H：
 - B&H 中位數僅 0.75%，這意味著有一半的時間，買入持有策略的獲利微乎其微，甚至不如銀行利息（0.79%）。
 - RL 方法（如 QLf, SARSA(λ)) 中位數高達 2.07%~2.40%。
 - 結論：在隨機的市場波動中，RL 策略能穩定地創造出 比 B&H 高出近 3 倍 的中位數回報。這證明了 RL 能夠有效過濾無效波動，在有獲利時果斷落袋。

2. 排名穩定性居冠

從報酬排名（Rank）來看，RL 是表現最穩定的策略群體。

- 平均排名第一：
 - QLf (使用 fBM 訓練) 取得了全場最佳的平均排名 4.98，是唯一平均排名進入前 5 名的策略。
 - 相比之下，B&H 平均排名為 6.79，MA 為 7.44，KD 為 7.96。
- 穩定的前段班：
 - RL 方法的排名標準差（Std）顯著低於 B&H，且中位數排名穩定維持在 5。這代表 RL 策略極少墊底，無論市場好壞，它都能維持在所有策略的前半段。

實驗2. 30天賣出

- e_t : 參考近3期的股票報酬，使用標準差法離散化為5個區塊
- M_t : 使用百分位數法離散為9個區塊
- α : 0.1
- γ : 0.85
- ϵ : 0.2
- λ : 0.4

- RL訓練次數為狀態數量的10倍
- 測試30天
- 訓練長度為測試的7倍
- 總共960次的測試

實際報酬比較

統計量	QL	SARSA	SARSA(λ)	B&H	?	MA	KD	RSI	MACD	💰	QLf	S
count	960	960	960	960	960	960	960	960	960	960	960	960
mean	0.47%	0.64%	0.68%	1.89%	1.36%	0.76%	0.48%	1.54%	0.78%	0.25%	0.33%	0.47%
std	7.89%	8.00%	8.88%	16.31%	11.92%	7.19%	5.34%	15.16%	6.35%	2.30%	8.18%	8.18%
min	-40.82%	-40.26%	-40.26%	-40.81%	-40.81%	-50.69%	-49.29%	-40.81%	-50.69%	-9.79%	-40.82%	-40.82%
25%	-0.83%	-0.68%	-1.28%	-6.08%	-3.40%	-1.63%	-1.38%	-5.38%	-1.32%	-0.69%	-1.15%	-1.15%
50%	1.03%	1.00%	1.51%	0.01%	0.10%	0.22%	0.21%	0.01%	0.23%	0.24%	1.04%	1.04%
75%	3.64%	3.69%	4.58%	6.73%	3.95%	1.97%	2.00%	5.39%	2.03%	1.05%	3.55%	3.55%
max	39.91%	39.91%	39.91%	97.92%	85.42%	82.84%	49.74%	96.62%	43.73%	11.59%	39.91%	85.42%

報酬排名比較

統計量	QL	SARSA	SARSA(λ)	B&H	?	MA	KD	RSI	MACD	💰	QLf	SARSAf	SARSA(λ)f
count	960	960	960	960	960	960	960	960	960	960	960	960	960
mean	5.48	5.50	5.45	6.32	7.30	7.05	7.19	6.57	6.89	7.48	5.63	5.50	5.46
std	3.10	3.09	3.29	4.34	4.12	3.81	3.72	4.24	3.69	4.23	3.15	3.16	3.33
min	1	1	1	1	1	1	1	1	1	1	1	1	1
25%	3	3	3	1	3	3	4	2	3	4	3	3	3
50%	5	5	5	6.5	8	7	8	7	7	9	5	5	5
75%	8	8	8	11	11	11	10	11	10	11	8	8	8
max	13	13	13	13	13	13	13	13	13	13	13	13	13

結果分析-實驗2(30天)

即使賣出天數調降至30天(短天期)，RL賣出方法的中位數優勢依舊存在，排名的平均還比B&H少了0.81，也就是說RL是穩穩賺錢的好方法。

實驗3. 100天賣出，強化版TA

參數設定和實驗1相同，但是強化了技術分析(TA)的賣出邏輯，賣出方法調整如下：

- MA：慢線 < 快線 $\Rightarrow$ 慢線由上往下穿越快線死亡交叉
- RSI：rsi > 70 $\Rightarrow$ 昨天 > 70 且 今天 < 70

- KD：K值 < D值 $\Rightarrow$ 高檔鈍化(K值>80)後死叉
- MACD：macd柱狀體 < 0 $\Rightarrow$ 昨天hist > 0 且 今天 hist < 0

實際報酬比較

統計量	QL	SARSA	SARSA(λ)	B&H	?	MA	KD	RSI	MACD	💰	QLf
count	960	960	960	960	960	960	960	960	960	960	960
mean	1.78%	2.05%	2.26%	5.40%	3.37%	2.61%	3.45%	3.45%	2.05%	0.85%	1.96%
std	8.66%	8.72%	9.82%	28.66%	19.08%	15.72%	23.17%	22.33%	14.90%	2.37%	9.25%
min	-50.38%	-42.94%	-48.12%	-53.95%	-47.12%	-38.81%	-52.45%	-53.95%	-44.80%	-9.29%	-50.38%
25%	0.07%	0.07%	0.70%	-10.80%	-6.01%	-4.22%	-6.72%	-7.05%	-4.31%	-0.20%	0.12%
50%	1.95%	2.00%	2.58%	0.46%	0.79%	0.64%	0.96%	0.69%	0.68%	0.79%	1.96%
75%	4.32%	4.69%	5.29%	14.35%	8.77%	6.28%	8.89%	8.33%	5.34%	1.73%	4.20%
max	76.78%	95.19%	105.53%	243.40%	147.11%	204.34%	243.40%	207.97%	208.39%	12.03%	102.01%

報酬排名比較

統計量	QL	SARSA	SARSA(λ)	B&H	?	MA	KD	RSI	MACD	💰	QLf	SARSAf	SARSA(λ)f
count	960	960	960	960	960	960	960	960	960	960	960	960	960
mean	5.56	5.44	5.40	6.67	7.10	7.24	6.86	7.00	7.45	8.04	5.49	5.54	5.55
std	3.09	3.03	3.16	4.71	4.15	3.90	4.21	4.17	3.77	4.03	3.07	3.08	3.25
min	1	1	1	1	1	1	1	1	1	1	1	1	1
25%	3	3	3	1	3	4	3	3	4	5	3	3	3
50%	5	5	5	7	7.5	8	8	8	8	9	5	5	5
75%	8	8	7	11	11	11	11	11	11	12	8	8	8
max	13	13	13	13	13	13	13	13	13	13	13	13	13

另一組參數設計

- e_t : 參考近7期的股票報酬，使用標準差法離散化為2個區塊
- M_t : 使用百分位數法離散為2個區塊
- α : 0.1
- γ : 0.85
- ϵ : 0.25
- λ : 0.25
- RL訓練次數為狀態數量的10倍
- 測試100天
- 訓練長度為測試的6倍
- 總共960次的測試

實際報酬比較

統計量	QL	SARSA	SARSA(λ)	B&H	?	MA	KD	RSI	MACD	💰	QLf
count	960	960	960	960	960	960	960	960	960	960	960
mean	2.21%	2.43%	2.41%	7.17%	3.85%	2.97%	4.03%	4.73%	2.40%	0.82%	2.13%
std	10.38%	10.19%	10.34%	37.40%	21.39%	15.70%	25.10%	26.90%	13.62%	2.48%	10.35%
min	-57.84%	-57.84%	-57.84%	-73.40%	-69.43%	-49.02%	-71.78%	-71.47%	-49.02%	-9.24%	-57.84%
25%	-0.18%	-0.11%	-0.03%	-8.95%	-5.78%	-3.35%	-6.47%	-6.32%	-3.09%	-0.15%	-0.22%
50%	2.61%	2.68%	2.76%	0.72%	0.90%	1.14%	0.68%	0.98%	1.07%	0.79%	2.60%
75%	5.85%	5.98%	6.29%	14.74%	8.15%	5.93%	9.28%	9.39%	5.13%	1.66%	5.82%
max	53.19%	53.19%	53.19%	516.72%	153.76%	229.17%	271.99%	331.93%	140.86%	10.87%	53.19%

報酬排名比較

統計量	QL	SARSA	SARSA(λ)	B&H	?	MA	KD	RSI	MACD	💰	QLf	SARSAf	SARSA(λ)f
count	960	960	960	960	960	960	960	960	960	960	960	960	960
mean	5.41	5.19	5.32	6.72	7.30	7.31	6.95	6.95	7.56	8.08	5.43	5.43	5.56
std	3.10	3.08	3.17	4.72	4.12	3.74	4.18	4.21	3.68	4.21	3.15	3.23	3.23
min	1	1	1	1	1	1	1	1	1	1	1	1	1
25%	3	3	3	1	3	4	3	3	4	5	3	3	3
50%	5	5	5	8	8	8	8	8	8	9	5	5	5
75%	7	7	7	11	11	10	11	11	11	12	8	7	8
max	13	13	13	13	13	13	13	13	13	13	13	13	13

結果分析-實驗3(100天，強化TA)

強化TA比原本的簡單TA好很多，平均報酬還有排名都到了能夠與隨機賣出一較高下的地步，但是RL的中位數以及排名仍然大幅輾壓這些基本、技術分析的方法。因此使用技術分析，不如長期持有或是用這裡的RL方法。

六. 結論與未來展望

本文使用三種RL方法，Q-learning、SARSA、SARSA(λ)來自動選擇最佳的賣股時機點，並且使用時間序列的拔靴法進行回測。與基本和技術分析方法比較，在中位數、Q1報酬以及報酬排名上大幅領先，表示RL能夠穩定的賺取報酬，取得了漂亮的成就。

未來可以嘗試reward改成別的績效指標，例如Sharpe或是Utility函數。或是不是一次賣出股票，動作可以換成一次賣出一部份的股票，讓操作更符合實務。

七.參考文獻

Corazza, M., & Sangalli, A. (2015). Q-learning and SARSA: A comparison between two intelligent stochastic control approaches for financial trading (Working Paper No. 15/WP/2015). Department of Economics, Ca' Foscari University of Venice.

Efron, B., & Tibshirani, R. J. (1993). An introduction to the bootstrap. New York, NY: Chapman & Hall/CRC.

Haruvi, Y. (2017). Applying bootstrap methods to time series and regression models. M.Sc. Seminar in Statistics, Tel Aviv University.

Powell, W. B. (2022). Reinforcement learning and stochastic optimization: A unified framework for sequential decisions. Hoboken, NJ: John Wiley & Sons.